


Università degli studi di Padova

DIPARTIMENTO DI MATEMATICA “TULLIO LEVI-CIVITA”

CORSO DI LAUREA IN INFORMATICA



**Applicazioni di ML, Clustering e
Predizione Next Best Action per
Campagne Omnicanale**

Tesi di laurea triennale

Relatore

Lamberto Ballan

Laureando

Angela Favaro

Matricola 2111015

*Alle mie nonne, Rita e Teresa.
A tutto l'amore che mi avete donato.*

Ringraziamenti

Ringrazio il professor Lamberto Ballan relatore della mia tesi.

Desidero ringraziare i miei genitori per avermi sempre lasciata libera in tutte le decisioni di vita.

Mia mamma Sabrina, che mi ha sempre fatta sentire al sicuro e mio papà Emilio, che non ci ha mai fatto mancare nulla.

Ringrazio poi i miei fratelli, Alba Azzurra e Leone, i miei primi amici.

Ringrazio Amanda, per tutte le cose indimenticabili che abbiamo vissuto e per aver scelto di conoscermi davvero.

Ringrazio Klarisa, che mi ha insegnato l'amicizia; Sara, a cui voglio un bene immenso; Alessandra che è una seconda sorella; Laura e Daniela, il mio piccolo branco e grazie a tutti gli amici per i ricordi bellissimi di questi anni.

Ci tengo infine a ringraziare tutti i colleghi di Blue BI SRL, in particolare Benedetta Dal Sasso ed il tutor aziendale Alberto Ferrara per il sostegno durante il progetto e per avermi dato l'opportunità di conoscere la loro realtà lavorativa.

Padova, Settembre 2026

Angela Favaro

Sommario

Il presente documento descrive il lavoro svolto durante il periodo di stage curricolare, della durata di circa trecentoventi ore, dal laureando Angela Favaro presso l'azienda Blue BI SRL. Lo stage è stato condotto sotto la supervisione del tutor aziendale Alberto Ferrara, mentre il prof. Lamberto Ballan ha ricoperto il ruolo di tutor accademico.

Il presente lavoro di tesi tratta lo studio preliminare e lo sviluppo di modelli di *clustering* e di predizione *Next Best Action* a supporto di strategie di ingaggio omnicanale. L'obiettivo principale risiede nella realizzazione di una *dashboard* riassuntiva che, illustrando l'output e il funzionamento dei modelli, offra agli *stakeholder* una visione concreta delle potenzialità applicative dell'Intelligenza Artificiale e del *Machine Learning*.

Organizzazione del testo

- Il **primo capitolo** introduce l'azienda, il progetto e le motivazioni che hanno portato a sceglierlo;
- Il **secondo capitolo** descrive il progetto e l'organizzazione del lavoro definendone gli obiettivi;
- Il **terzo capitolo** presenta nel dettaglio lo svolgimento del progetto ed i risultati ottenuti;
- Il **quarto capitolo** traccia una breve analisi conclusiva sul lavoro svolto.

Convenzioni tipografiche

Durante la stesura del testo sono state adottate le seguenti convenzioni tipografiche:

- Gli acronimi, le abbreviazioni e i termini di uso non comune menzionati vengono definiti nel glossario, situato alla fine del documento (p. 63);

- Per la prima occorrenza dei termini riportati nel glossario viene utilizzata la seguente nomenclatura: *termine_G*;
- I termini in lingua straniera non di uso comune o facenti parti del gergo tecnico sono evidenziati con il carattere *corsivo*;
- I nomi di funzioni o variabili appartenenti ad un linguaggio di programmazione vengono scritte con un carattere **monospaziato**;
- Le citazioni relative a fonti, articoli e documentazioni ufficiali consultati per lo svolgimento del progetto sono raccolte nella sitorgrafia (p. 67); i link di approfondimento e le risorse esterne sono indicati nel testo da un numero in apice con il relativo URL riportato a piè di pagina.
- I blocchi di codice sono rappresentati nel seguente modo

```
1 float Assegnazione ( float number ){  
2     float y;  
3     y = number;  
4     return y;  
5 }
```

Codice 1: Codice d'esempio.

Indice

1	Introduzione	1.
1.1	L'azienda	1.
1.2	Il progetto	3.
1.2.1	Contesto	3.
1.2.2	I canali	4.
1.2.3	Costruzione del progetto	5.
1.3	Motivazioni di scelta del progetto	5.
2	Descrizione stage	7.
2.1	Aspettative di apprendimento	7.
2.2	Obiettivi del progetto	8.
2.2.1	Obiettivi fissati	9.
2.3	Pianificazione	10.
2.3.1	Pianificazione iniziale	11.
2.3.2	Discostamenti dalla pianificazione	12.
3	Svolgimento del progetto	15.
3.1	Stack tecnologico ed ambiente di sviluppo	15.
3.2	Analisi ed esplorazione preliminare dei dati	16.
3.2.1	Analisi tabella anagrafica	17.
3.2.2	Analisi tabelle delle azioni	22.
3.3	Profilazione della <i>digital attitude</i> tramite Clustering	28.
3.3.1	K-Means: fondamenti teorici	29.
3.3.2	Feature Engineering per la misura dell'attitudine digitale	30.
3.3.2.1	Regole deterministiche	30.
3.3.2.2	Ingegnerizzazione delle <i>feature</i> per il <i>Machine Learning</i>	31.
3.3.3	Implementazione, addestramento e valutazione del modello	33.
3.3.3.1	Implementazione	33.

3.3.3.2	Addestramento	33.
3.3.3.3	Risultati del modello	35.
3.3.4	Valutazione dei risultati	38.
3.4	Modellazione predittiva per la Next Best Action (NBA)	39.
3.4.1	Sperimentazione con le <i>Markov Chains</i>	39.
3.4.1.1	Analisi e criticità delle Catene di Markov	40.
3.4.2	Sperimentazione con il <i>Gradient Boosting</i>	41.
3.4.2.1	<i>CatBoost</i> : fondamenti teorici	42.
3.4.2.1.1	Esperimenti condotti e analisi delle criticità	43.
3.4.3	Predizione NBA: <i>Gradient Boosting</i> con <i>LightGBM</i>	43.
3.4.3.1	<i>Data preparation & engineering</i>	45.
3.4.3.2	Addestramento del classificatore	47.
3.4.3.2.1	Addestramento Modello 1: modello di saturazione (<i>Binary Model</i>)	48.
3.4.3.2.2	Addestramento Modello 2: selettore strategico di canale (<i>Multiclass Model</i>)	49.
3.4.3.3	Regole di business - Post processing	50.
3.4.3.4	Valutazione e validazione delle performance	50.
3.4.3.4.1	Performance modello 1	51.
3.4.3.4.2	Performance modello 2	52.
3.4.3.4.3	Performance generali	53.
3.5	Caso d'uso applicativo	54.
4	Conclusioni	59.
4.1	Consuntivo finale	59.
4.2	Raggiungimento degli obiettivi	60.
4.3	Criticità riscontrate e interventi di mitigazione	61.
4.4	Valutazione personale	62.
	Glossario	63.
	Sitografia	67.

Elenco delle Figure

Figura 1	Logo dell'azienda Blue Bi.	1.
Figura 2	Logo di Databricks.	15.
Figura 3	Analisi distribuzione della <i>DIGITAL ATTITUDE</i>	21.
Figura 4	Analisi distribuzione della <i>SEGMENTATION</i>	21.
Figura 5	Analisi distribuzione della <i>SPECIALTY</i>	21.
Figura 6	Analisi distribuzione delle possibili azioni.	26.
Figura 7	Analisi distribuzione delle azioni digitali.	27.
Figura 8	Analisi distribuzione delle azioni tra gli RTE nel tempo.	27.
Figura 9	Analisi distribuzione delle azioni tra i DEM nel tempo. .	27.
Figura 10	Analisi distribuzione delle azioni tra le visite.	28.
Figura 11	Analisi distribuzione delle azioni tra le visite nel tempo. .	28.
Figura 12	Analisi distribuzione delle azioni nel tempo.	28.
Figura 13	Analisi sulla scelta di k utilizzando l' <i>Elbow Method</i>	34.
Figura 14	<i>Heatmap</i> derivata dall'algoritmo k-Means.	35.
Figura 15	Importanza delle feature usate dall'algoritmo k-Means . .	38.
Figura 16	Distribuzione dei cluster sul dataset.	38.
Figura 17	Esempio catena di Markov. ¹	40.
Figura 18	Confronto tra strategia di crescita Leaf-wise (a sinistra) e Level-wise (a destra). ²	44.
Figura 19	Matrice di confusione, modello 1.	51.
Figura 20	Distribuzione indice di saturazione.	51.
Figura 21	Matrice di confusione, modello 2.	52.
Figura 22	Distribuzione suggerimenti del modello sull'intero dataset.	53.
Figura 23	Distribuzione mediana delle probabilità dei modelli.	54.

¹Fonte: Joxemai4 - Own work, CC BY-SA 3.0.

²Fonte: Bzubeda, 'Machine Learning 101', Medium, Gennaio 2024

Figura 24	Vista generale della dashboard finale - cluster deterministico.	54.
Figura 25	Vista generale della dashboard finale - cluster non deterministico.	55.
Figura 26	Vista delle informazioni generali dell'HCP nella <i>dashboard</i>	55.
Figura 27	Vista delle probabilità calcolate dai modelli.	56.
Figura 28	Vista delle flags, dei cluster e del processo decisionale spiegati.	57.
Figura 29	Vista sulla timeline all'interno della dashboard.	57.

Elenco delle Tabelle

Tabella 1	Tracciamento degli Obiettivi Obbligatorii.	10.
Tabella 2	Tracciamento degli Obiettivi Desiderabili.	10.
Tabella 3	Pianificazione del lavoro.	11.
Tabella 4	Svolgimento effettivo del lavoro.	12.
Tabella 5	Campi della tabella <code>hcp_epi_in_scope_it</code>	17.
Tabella 6	Campi della tabella <code>visit_epi_it</code>	22.
Tabella 7	Campi delle tabelle <code>dem_epi_it</code> e <code>rte_epi_it</code>	24.
Tabella 8	Feature individuate per l'algoritmo di clustering.	31.
Tabella 9	Cluster individuati dal k-Means.	36.
Tabella 10	Feature di preparazione ai modelli predittivi.	46.
Tabella 11	Consuntivo orario finale.	59.
Tabella 12	Obiettivi raggiunti.	60.
Tabella 13	Criticità riscontrate e interventi di mitigazione.	61.

Elenco dei Codici Sorgente

Codice 1	Codice d'esempio.	viii
Codice 2	Trim su `KEY_COUNTRY_CONTACT`.	25.
Codice 3	Implementazione essenziale modello K-Means utilizzato. .	34.
Codice 4	Implementazione essenziale del Modello Binario.	48.
Codice 5	Implementazione essenziale del modello multiclasse.	49.

Capitolo 1

Introduzione

Il presente capitolo è dedicato alla contestualizzazione della realtà aziendale e del progetto. Viene delineato il profilo di Blue BI. Segue una descrizione della proposta progettuale, per poi concludere con l'analisi delle motivazioni che hanno indirizzato alla scelta del progetto.

1.1 L'azienda



Figura 1: Logo dell'azienda Blue Bi.

Blue BI è una società specializzata nel campo della *Business Intelligence (BI)_G* e *Business Analytics (BA)_G* con una consolidata esperienza nel disegno, implementazione e gestione di sistemi di analisi delle performance.

Opera sul territorio nazionale attraverso cinque sedi operative situate a Milano, Roma, Torino, Vicenza e Cesena.

Le collaborazioni con i partner e i clienti si estendono su molteplici settori industriali, tra cui Fashion e Lusso, Media e Comunicazioni, Farmaceutica, Consulenza Business, Servizi Professionali, Assicurazioni e Banche, Trasporti e Logistica, Manifattura industriale e Hospitality.

L'azione e la cultura di Blue BI si fondano su un insieme di **valori portanti**. L'attività quotidiana è guidata da elevati standard di *eccellenza e integrità* professionale, supportati da un costante impegno nell'*apprendimento continuo* per rispondere con prontezza alle evoluzioni del mercato. L'ambiente di lavoro promuove il *rispetto reciproco e l'inclusione*, incoraggiando la *collaborazione* per garantire un clima collettivo sereno e gratificante. Infine, l'azienda individua nella *resilienza*

e nella *crescita individuale* i motori fondamentali per lo sviluppo del talento, dell'imprenditorialità e il raggiungimento di traguardi comuni.

Il portafoglio dei **servizi offerti** si articola principalmente su tre direttrici strategiche:

1. *Consulenza*
attività che spaziano dalla realizzazione di *Proof of Concept (PoC)_G* alla selezione del software più idoneo, passando per il *BI Assessment* e la gestione del cambiamento tecnologico (*Change Management*).
2. *Implementazione del sistema*
progettazione e sviluppo di architetture di *Business Intelligence & Analytics*, con un focus sulla rapidità di implementazione tramite soluzioni proprietarie e sul coordinamento di progetti di *roll-out* internazionali.
3. *Mantenimento e Infrastruttura*
erogazione di servizi di assistenza continua e manutenzione applicativa, affiancati da soluzioni in ambienti *Cloud Computing* e *Software as a Service* (SaaS).

L'azienda inoltre **investe nell'esplorazione di tecnologie emergenti** per anticipare le esigenze del mercato. Le principali linee di ricerca interne includono:

- *Mixed Reality*: studio dell'integrazione di report e grafici 2D/3D all'interno di ambienti di realtà aumentata e virtuale (AR/VR), con l'obiettivo di abilitare l'ancoraggio spaziale dei dati e migliorare l'interattività delle *dashboard_G*.
- Integrazione *Chatbot*: sviluppo di interfacce conversazionali avanzate con comandi vocali per rendere l'accesso ai dati aziendali e alla *business intelligence* più immediato e accessibile.
- GenAI: implementazione di use cases aziendali basati sui più recenti *Foundation Models*, sfruttando le API di ChatGPT e i servizi *cloud-native* per l'estrazione di conoscenza.
- **Analisi predittive**: applicazione di algoritmi di *Machine Learning*, alberi decisionali e reti neurali per l'analisi predittiva e la modellazione statistica dei dati storici dei clienti.

In quest'ottica, sono in atto collaborazioni strategiche con *OpenAI*, *Amazon Web Services (AWS)* e *Databricks*: tre piattaforme leader nel settore *cloud-native* che mettono a disposizione dell'azienda le tecnologie e l'infrastruttura necessarie per lo sviluppo, l'elaborazione dei dati e l'implementazione di applicazioni intelligenti di ultima generazione.

L'**obiettivo strategico** aziendale risiede proprio nel capitalizzare questi investimenti per trasformare i dati in valore reale.

L'estrazione di *insight_G* accurati e la proposta di soluzioni fortemente

innovative permettono infatti ai clienti di ottimizzare i processi interni, prosperare nel proprio settore e mantenere un solido vantaggio competitivo sul mercato.

1.2 Il progetto

1.2.1 Contesto

Uno specifico ambito in cui l'azienda opera è quello delle campagne di **marketing farmaceutico omnicanale**, strategia che prevede l'uso integrato e sinergico di diversi canali di comunicazione per interagire con i clienti in modo coerente e personalizzato.

Blue BI sta sviluppando soluzioni di gestione ed analisi dei dati per rispondere alle esigenze odierne del mercato.

Il progetto di tesi si concentra sull'applicazione di tecniche di *Machine Learning* per massimizzare l'efficacia delle campagne di marketing omnicanale sul singolo.

L'**obiettivo principale** risiede nello sviluppo di modelli predittivi che consentano di segmentare i destinatari in base al loro comportamento digitale e alle preferenze manifestate, al fine di personalizzare le strategie di comunicazione e ottimizzare le interazioni complessive.

Il fulcro logico dell'attività predittiva è rappresentato dal concetto di *Next Best Action* (**NBA_G**).

La NBA identifica l'azione o il canale di comunicazione più appropriato da proporre ad un determinato utente in un dato momento.

L'implementazione di tale modello predittivo si basa sull'analisi approfondita dei dati storici, finalizzata ad identificare pattern comportamentali ricorrenti e prevedere l'interazione futura con la maggiore probabilità di successo.

Gli utenti finali per i quali il progetto è stato pensato sono i **Rappresentanti Farmaceutici (REP_G)** o *Sales Representatives*.

Figure professionali che interagiscono con i professionisti del settore sanitario per svolgere attività di informazione scientifica e presentare i prodotti dell'azienda farmaceutica per cui operano.

I destinatari dell'attività dei REP vengono chiamati **Health Care Professionals (HCP_G)**. Rappresentano una categoria di professionisti che opera nel settore sanitario (medici, farmacisti, ecc.) e che interagisce con le campagne di marketing delle aziende farmaceutiche.

Il modello predittivo analizza e interpreta i comportamenti multi-canale di questi ultimi al fine di suggerire al rappresentante l'azione statisti-

camente più efficace da intraprendere nella fase successiva dall'ultimo contatto, massimizzando così il livello di *engagement* dell'HCP.

1.2.2 I canali

Le interazioni che i rappresentanti possono avere con gli HCP si articolano tra due principali macroaree: *visite dirette* e *comunicazioni digitali*.

Le visite dirette costituiscono il canale di interazione frontale tra il REP e il professionista sanitario.

Questa categoria si suddivide a sua volta in tre specifici sottocanali:

- **Visite $F2F_G$ (*Face to Face*):** rappresentano i colloqui in presenza, durante i quali il REP incontra fisicamente l'HCP.

In questa sede, un rappresentante può supportare la conversazione attraverso strategie di **CLM_G (*Closed-Loop Marketing*)**, avvalendosi di dispositivi digitali per presentare contenuti multimediali o di supporto alla conversazione. L'utilizzo del CLM è molto importante, permette infatti di registrare in background dati dettagliati sulle reazioni e sugli interessi dell'HCP; offrono una base informativa preziosa per personalizzare ulteriormente le future interazioni.

- **Phone Call:** rappresentano le interazioni telefoniche tra il REP ed il professionista sanitario.
- **Video Call:** colloqui da remoto tramite piattaforme di videoconferenza, costituiscono un indicatore rilevante del livello di digitalizzazione e della disponibilità dell'HCP all'uso di canali virtuali.

Le comunicazioni digitali si configurano come punti di contatto (*touchpoint*) indiretti. Principalmente veicolati tramite posta elettronica. Questi contatti sono tracciati ed il tracciamento è cruciale per misurare il livello di coinvolgimento (*engagement*) del singolo professionista sia all'interno della campagna, che per valutarne il grado di maturità digitale.

All'interno di questa macroarea si distinguono:

- **DEM_G (*Direct Email Marketing*):** comunicazioni inviate su scala ampia, pianificate centralmente dal reparto marketing e indirizzate a specifici segmenti di target per supportare il lancio di prodotti o la diffusione di informative scientifiche.
- **RTE_G (*Real-Time Email*):** comunicazioni elettroniche inviate in modo mirato e personalizzato al singolo HCP. Questa tipologia viene utilizzata proattivamente dal REP, solitamente a seguito di un incontro frontale ($F2F$ o *Video Call*), per fornire materiali di approfondimento su richiesta o per dare continuità alla relazione informativa innescata dal contatto diretto.

1.2.3 Costruzione del progetto

Il progetto si articola in due macrofasi sequenziali di ricerca tecnologica e sviluppo.

Prima fase: Clustering e profilazione comportamentale

In un primo momento, l'attività si concentra sull'analisi esplorativa dei dati storici al fine di identificare pattern comportamentali e segmentare gli utenti in gruppi (o *cluster*) omogenei.

L'obiettivo di questa fase è lo sviluppo di un modello di *clustering* capace di mappare e misurare la **Digital Attitude** (attitudine digitale) di ogni singolo HCP.

Tale metrica consente al rappresentante di comprendere preventivamente il grado di ricettività digitale dell'HCP durante lo svolgimento delle campagne marketing.

Seconda fase: modellazione predittiva per la Next Best Action

Una volta assegnato ciascun target a uno specifico profilo comportamentale, la conoscenza estratta viene utilizzata come base di partenza per la fase predittiva.

L'obiettivo di questo secondo passo è l'implementazione di un modello di *Machine Learning* che proponga un'azione da eseguire verso ogni HCP. Il sistema elabora una raccomandazione dinamica analizzando la sequenza cronologica delle ultime interazioni effettuate verso il medico e il rispettivo livello di risposta manifestato dal professionista a quegli specifici stimoli.

1.3 Motivazioni di scelta del progetto

La scelta del progetto è stata determinata da una combinazione di fattori legati sia dal contesto applicativo che dall'alto valore formativo della proposta aziendale.

Una prima motivazione risiede nell'interesse verso il mondo della *Data-Science* e dell'analisi dei dati.

Il percorso di studi triennale si concentra nel fornire solide basi metodologiche incentrate principalmente sulla progettazione e sulla costruzione di sistemi software tradizionali, lo studio dei dati rappresenta uno stimolante completamento del profilo accademico.

La prospettiva di approfondire le metodologie di estrazione del valore dai dati ha trovato una corrispondenza nelle proposte progettuali offerte dall'azienda.

In seconda battuta l'integrazione del progetto con le tecnologie di *Machine Learning* costituisce un'opportunità formativa irrinunciabile. Nel panorama informatico contemporaneo, la comprensione di questi paradigmi non è più un elemento opzionale, ma uno strumento la cui conoscenza è fondamentale.

Ulteriori elementi di forte interesse sono emersi dall'analisi del contesto applicativo.

L'elaborazione di modelli basati sulle interazioni umane e comportamentali, in contrasto con le più lineari analisi di mercato quantitative, ha aumentato la curiosità e introdotto una sfida stimolante.

L'adozione del paradigma di *Next Best Action* (NBA) permette di estendere il raggio d'azione della classica analisi predittiva (*Forecasting_G*). Non ci si limita a prevedere un trend futuro passivo, ma si identifica dinamicamente l'azione ottimale per guidare l'operato umano.

Infine, un ruolo determinante è stato ricoperto dal dialogo costruttivo instauratosi con i referenti aziendali. L'apertura, la disponibilità e la chiarezza dimostrate nell'esposizione degli obiettivi hanno confermato la validità dell'azienda per lo svolgimento del tirocinio, distinguendosi rispetto ad altre realtà pur parimenti stimolanti.

Il punto di forza del progetto è che si differenzia dalle classiche esperienze di sviluppo software. L'obiettivo finale non risiede nella codifica di un sistema applicativo gestionale, bensì nell'attività di ricerca, addestramento e validazione di modelli statistici e predittivi, destinati a essere integrati nei processi interni dell'azienda o nei servizi offerti ai clienti.

Capitolo 2

Descrizione stage

In questo capitolo verrà approfondita l'organizzazione dello stage, le aspettative, gli obiettivi prefissati e il discostamento effettivo dall'organizzazione a monte.

2.1 Aspettative di apprendimento

Lo stage presenta un rilevante valore formativo perché consente di applicare conoscenze teoriche di analisi dei dati, statistica e *Machine Learning* a un caso reale in ambito aziendale.

Dal punto di vista strettamente tecnico e metodologico, come accennato nella Sezione 1.2, le principali aspettative di apprendimento e consolidamento riguardano:

Modellazione statistica e Machine Learning su dati comportamentali;
apprendere a gestire dati reali e complessi legati alle interazioni umane, traducendo eventi qualitativi e temporali in variabili per un'analisi predittiva;

Tecniche di classificazione, clustering e regressione;
approfondire l'uso degli algoritmi non supervisionati per l'identificazione di gruppi omogenei di utenti e di quelli supervisionati;

Feature engineering e costruzione di indicatori sintetici;
sviluppare la capacità di trasformare dati grezzi di tracciamento in variabili ad alto valore informativo, capaci di sintetizzare in modo efficace un dataset;

Valutazione delle performance dei modelli;
acquisire rigore nell'uso di metriche quantitative e metodologie di validazione per misurare l'accuratezza, la robustezza e la capacità di generalizzazione degli algoritmi sviluppati;

Interpretazione dei risultati (Data Visualization_G);
apprendere le tecniche di rappresentazione grafica dei dati, indispensabili per tradurre gli output analitici in report e *dashboard* chiare, rendendo i

pattern emersi e le raccomandazioni logiche facilmente intellegibili anche ad utenti non tecnici;

Integrazione di modelli analitici in contesti aziendali reali;
comprendere come un modello teorico possa trasformarsi in uno strumento operativo utilizzabile all'interno dei processi decisionali del cliente, rispettando vincoli di business e requisiti di efficienza.

A fianco dell'innalzamento delle competenze tecniche, un'aspettativa rilevante è rappresentata dalla **comprensione del contesto aziendale**. Il tirocinio costituisce un'opportunità preziosa per confrontarsi con l'organizzazione del lavoro in un'azienda di consulenza, apprendere le logiche della gestione dei progetti per obiettivi e comprendere come le esigenze dei clienti e degli utenti finali guidino ogni scelta architetture e modellistica.

Questa esperienza si propone dunque di affinare anche la capacità di comunicazione interpersonale, il lavoro in team e la flessibilità operativa necessarie per muoversi nel mondo professionale.

2.2 Obiettivi del progetto

Il percorso di stage si propone di introdurre e applicare le principali metodologie in uso negli ambiti della *Business Intelligence* e dell'Intelligenza Artificiale, attraverso lo sviluppo di un progetto orientato all'analisi del comportamento digitale degli utenti e all'ottimizzazione delle strategie omnicanale.

Per raggiungere questo traguardo le attività progettuali sono volte all'ingegnerizzazione di un ciclo di vita del dato, che parte dalla fase di acquisizione e pre-elaborazione delle interazioni storiche degli HCP fino all'addestramento e alla validazione di algoritmi predittivi basati sul concetto di *Next Best Action* (NBA).

In questo contesto, il lavoro da svolgere è stato strutturato attorno a tre macroaree operative, che delineano gli obiettivi tecnici e metodologici del progetto:

1. Ingegnerizzazione dei dati e *Feature Engineering*

Il primo obiettivo riguarda la preparazione della base informativa. Questa fase prevede l'estrazione e l'integrazione dei dati storici relativi alle interazioni multi-canale, tra cui visite F2F, chiamate telefoniche, *video call* ed email (DEM e RTE). A seguito di un'accurata fase di pre-elaborazione orientata alla gestione dei dati mancanti, al trattamento degli *outlier* e alla normalizzazione delle variabili temporali e frequen-

ziali. L'attività si concentra poi sulla costruzione di un set di feature aggregate e indicatori sintetici.

2. Modellazione analitica e *Machine Learning*

La seconda macroarea costituisce il cuore algoritmico del progetto e si focalizza sullo sviluppo dei modelli analitici. In un primo momento, vengono applicate tecniche di apprendimento non supervisionato per analizzare i pattern comportamentali ed effettuare una segmentazione targettizzata degli HCP. Successivamente, la conoscenza estratta viene integrata all'interno di classificatori supervisionati e modelli di propensione, con il fine di stimare la probabilità di conversione sui diversi canali digitali e definire l'architettura predittiva in grado di raccomandare la *Next Best Action* più efficace.

3. Validazione e valutazione delle performance

L'ultima macroarea è dedicata alla verifica e all'ottimizzazione della soluzione modellata, garantendo il rigore scientifico del lavoro svolto. A seguito di uno studio preventivo delle possibili architetture analitiche che avrà condotto alla scelta del modello più idoneo al contesto applicativo, viene definito un quadro metodologico di valutazione basato su metriche quantitative specifiche per il tipo di algoritmo adottato. L'analisi continua delle metriche di performance permette così di guidare il processo iterativo di perfezionamento e taratura dei parametri del modello, garantendone la massima efficacia operativa.

Al fine di acquisire le competenze verticali necessarie all'utilizzo dello stack tecnologico di progetto, la fase iniziale prevede un percorso di **formazione e autoapprendimento**. Tale attività si è avvalsa della piattaforma *Udemy*³, messa a disposizione dall'azienda.

2.2.1 Obiettivi fissati

Notazione

Si farà riferimento agli obiettivi secondo le seguenti notazioni:

- OO per gli obiettivi obbligatori, vincolanti in quanto obiettivo primario; sono presenti in Tabella 1.
- OD per gli obiettivi desiderabili, non vincolanti o strettamente necessari, ma dal riconoscibile valore aggiunto; sono presenti in Tabella 2.

Le sigle precedentemente indicate saranno seguite da dei numeri, identificativi del requisito.

³<https://business.udemy.com/it>

Codice	Descrizione	Origine
OO1	Comprensione e analisi dei dati comportamentali digitali	Tutor aziendale
OO2	Sviluppo di un modello di <i>Digital Attitude</i>	Tutor aziendale
OO3	Implementazione di modelli di classificazione e regressione	Tutor aziendale
OO4	Valutazione delle performance tramite metriche statistiche.	Tutor aziendale

Tabella 1: Tracciamento degli Obiettivi Obbligatori.

Codice	Descrizione	Origine
OD1	Ottimizzazione dei modelli e miglioramento delle performance.	Tutor aziendale
OD2	Definizione di segmentazioni utilizzabili per campagne omnicanale.	Tutor aziendale

Tabella 2: Tracciamento degli Obiettivi Desiderabili.

2.3 Pianificazione

Lo stage è stato strutturato con una durata complessiva di quaranta giornate lavorative; per un totale di 320 ore.

Il lavoro è stato svolto a stretto contatto con il referente aziendale e con i colleghi del team di soluzione presso la sede Blue BI di Vicenza.

2.3.1 Pianificazione iniziale

N° attività	Giorno	Durata (giorni)	Descrizione
1	18 maggio - 25 maggio	sei	<u>Formazione e contestualizzazione.</u> Introduzione al contesto omnicanale e al comportamento digitale degli utenti. Analisi dei dataset disponibili.
2	26 maggio - 9 giugno	dieci	<u>Analisi esplorativa dei dati.</u> Studio delle variabili comportamentali e costruzione della <i>Digital Attitude</i> . Identificazione delle feature rilevanti
3	10 giugno - 29 giugno	quattordici	<u>Sviluppo modelli.</u> Implementazione di modelli di classificazione e regressione per segmentazione e propensione ai canali
4	30 giugno - 8 luglio	sette	<u>Validazione modelli e valutazione performance,</u> confronto approcci e interpretazione risultati in ottica business
5	9 luglio - 13 luglio	tre	<u>Documentazione e presentazione finale.</u> Redazione della documentazione tecnica e funzionale. Sintesi dei risultati ottenuti. Preparazione della presentazione finale del lavoro svolto.

Tabella 3: Pianificazione del lavoro.

2.3.2 Discostamenti dalla pianificazione

Nella Tabella 4, l'utilizzo dell'asterisco (*) in apice specifica le modifiche riorganizzative apportate rispetto al piano iniziale:

- In corrispondenza di «**N° attività**», indica una variazione sostanziale nella natura o nella struttura dell'attività;
- In corrispondenza di «**Durata (giorni)**», evidenzia una revisione della tempistica preventivata a monte.

N° attività	Giorno	Durata (giorni)	Descrizione
1	18 maggio - 25 maggio	sei	<u>Formazione e contestualizzazione.</u> Introduzione al contesto omnicanale e al comportamento digitale degli utenti. Analisi dei dataset.
2	26 maggio - 28 maggio	tre*	<u>Analisi esplorativa</u> dei dati. Studio delle variabili comportamentali. Identificazione delle feature rilevanti
3.1*	29 maggio - 12 giugno	undici*	<u>Costruzione della Digital Attitude.</u> Sviluppo modello di <i>clustering</i> . Confronto e studio dei vari approcci con validazione finale. Valutazione delle performance e interpretazione dei risultati in ottica business.

N° attività	Giorno	Durata (giorni)	Descrizione
3.2*	15 giugno - 30 giugno	dodici*	<u>Sviluppo modelli per Next Best Action.</u> Confronto e studio dei vari approcci con valutazione finale. Valutazione delle performance e interpretazione di risultati in ottica business
4*	1 luglio - 3 luglio	tre*	<u>Preparazione della dashboard di esposizione dei risultati.</u>
5	6 luglio - 13 luglio	sei*	<u>Documentazione e presentazione finale.</u> Redazione della documentazione tecnica e funzionale.

Tabella 4: Svolgimento effettivo del lavoro.

Capitolo 3

Svolgimento del progetto

In questo capitolo verranno illustrate le tappe della costruzione del progetto e dei modelli correlati.

Si partirà dalla ricerca, per poi passare all'implementazione e infine alla realizzazione di una dashboard esemplificativa del lavoro svolto.

3.1 Stack tecnologico ed ambiente di sviluppo



Figura 2: Logo di Databricks.

L'intero progetto è stato realizzato all'interno della piattaforma **Databricks**⁴, che ha fornito l'infrastruttura analitica e l'ambiente di sviluppo integrato.

Databricks è una piattaforma di analisi dati unificata su cloud che implementa l'architettura *Data Lakehouse_G*. Sviluppata dai creatori di *Apache Spark*⁵, la piattaforma consente di integrare in un unico ecosistema le attività di *Data Engineering*, *Data Science* e *Business Intelligence*.

Grazie all'integrazione nativa con *Delta Lake_G* (che garantisce la consistenza transazionale ACID e l'indicizzazione dei dati) e *MLFlow_G* (per il tracciamento, la riproducibilità e il *deployment* dei modelli di Machine Learning), Databricks permette di gestire l'intero ciclo di vita del dato: dall'ingestione e pulizia delle sorgenti grezze fino all'addestramento degli algoritmi predittivi e alla loro integrazione nei processi aziendali.

La parte di sviluppo è stata svolta utilizzando i **notebook** nativi di Databricks.

⁴<https://www.databricks.com>

⁵<https://spark.apache.org>

In questo ambiente è possibile impiegare simultaneamente diversi linguaggi (sia di programmazione che di gestione dei dati). L'implementazione ha combinato l'uso dei linguaggi **Python**⁶ e **SQL**⁷ grazie all'integrazione fornita da *PySpark*⁸, l'API Python per **Apache Spark**.

Apache Spark rappresenta il motore *open-source* di calcolo distribuito sottostante, progettato per l'elaborazione ad altissime prestazioni di grandi volumi di dati (*Big Data*) in memoria. Sfruttando l'architettura di Spark attraverso PySpark, è stato possibile manipolare e interrogare la base dati in maniera fluida all'interno dello stesso *notebook*, convertendo in modo trasparente le strutture dati tra *Spark Dataframe* e tabelle SQL temporanee in base alle specifiche esigenze analitiche.

Per automatizzare e rendere riproducibili le fasi di trasformazione del dato, sono state strutturate apposite **pipeline di elaborazione**. Tali pipeline hanno lo scopo di gestire l'intero ciclo di vita del dato a supporto della modellazione: dalle procedure preliminari di pulizia del dato e pre-elaborazione (*preprocessing*) per l'alimentazione degli algoritmi, fino alle fasi di *post-processing*, necessarie per ricondurre gli output predittivi nel formato idoneo alla fruizione aziendale.

Infine, a supporto delle attività di sviluppo del codice, per il refactoring degli script Python/PySpark e durante le sessioni di *brainstorming* sulla logica degli algoritmi, è stato utilizzato uno strumento di intelligenza artificiale generativa **Gemini PRO**⁹(Google, 2026).

3.2 Analisi ed esplorazione preliminare dei dati

All'interno del progetto sono state inizialmente analizzate quattro tabelle grezze. Da queste il passo iniziale è stato leggerle, comprenderle ed estrapolarne le informazioni utili allo sviluppo dell'intero progetto.

Si tratta quindi di un lavoro analitico di comprensione profonda e personale del *dataset*.

È stato inoltre necessario pulire le tabelle per poter comprendere meglio i dati a disposizione.

I *dataset* sorgente, resi disponibili come file **.csv**, sono stati importati nell'ambiente Databricks e convertiti in tabelle (*Delta Table* / tabelle

⁶<https://www.python.org>

⁷https://it.wikipedia.org/wiki/Structured_Query_Language

⁸<https://docs.databricks.com/aws/en/pyspark>

⁹<https://gemini.google.com>

di *metastore*). Questa operazione ha consentito di accedere ai *dataset* direttamente tramite query SQL ed ecosistema PySpark.

Le tabelle a disposizione si dividono in due macro-gruppi: una tabella anagrafica e tre tabelle delle azioni.

3.2.1 Analisi tabella anagrafica

La tabella, denominata «hcp_epi_in_scope_it», raccoglie le informazioni relative agli HCP (*Healthcare Professional*) coinvolti nel progetto. Nello specifico, non è stata resa disponibile l'intera anagrafica aziendale, ma soltanto un sottoinsieme riferito a una determinata campagna omnicanale svolta in precedenza sull'epilessia (da cui l'acronimo «*epi*» nel nome della tabella). Il campione comprende all'circa 800 HCP. Sulla tabella sono state condotte le prime attività di pulizia e analisi esplorativa.

Prima fase: pulizia e selezione delle colonne

In seguito a una prima analisi della struttura dati, lo studio si è focalizzato sulla comprensione del significato di ciascun campo, avvalendosi del supporto dei referenti aziendali. Una volta definiti i significati delle singole variabili, si è proceduto con una prima scrematura dei campi non rilevanti ai fini della modellazione.

Di conseguenza a questa selezione iniziale, sono state mantenute le variabili riportate nella Tabella 5.

Campo	Spiegazione
CONTACT_ID	Codice identificativo unico alfanumerico del singolo HCP, strutturato su cinque blocchi separati da trattini (es. CN60556O-8V51-4667-9436-R7E5446799U9). Rappresenta la chiave primaria della tabella.
NAME	Nome e cognome del professionista sanitario (unificati in un unico campo).

Campo	Spiegazione
EMAIL	Indirizzo di posta elettronica dell'HCP.
DIGITAL_ATTITUDE	Indice del comportamento e della propensione digitale dell'HCP tracciato dall'azienda nel 2023, il quale si divide nei profili <i>Conservative</i> , <i>Smart</i> ed <i>Explorer</i> . Sebbene la variabile non presenti aggiornamenti recenti, è stata mantenuta come potenziale feature per le analisi successive.
SEGMENTATION	Classificazione del valore strategico dell'HCP per l'azienda farmaceutica, suddivisa nei seguenti target: • <i>A</i>: HCP di primaria importanza ed elevato potenziale strategico. • <i>B</i>: HCP di rilevanza medio-alta. • <i>C</i>: HCP a medio-basso potenziale o con interazioni limitate. • <i>D</i>: HCP a basso valore prioritario per la campagna.
SPECIALTY_ONEKEY_1_DESC	Descrizione della specializzazione clinica primaria dell'HCP.
REP_ID	Codice identificativo del REP (rappresentante) assegnato alla gestione dell'HCP per la specifica campagna.

Campo	Spiegazione
ADOPTION_LADDER	Indicatore dello stadio di adozione del farmaco da parte del medico (scala di adozione), categorizzato in: • <i>Tiralist</i>: HCP che ha iniziato a prescrivere o testare il farmaco/prodotto su un numero limitato di pazienti. • <i>Regular User</i>: HCP prescrittore abituale che ha consolidato l'uso del prodotto nella propria pratica clinica. • <i>Non User</i>: HCP che non prescrive o non ha ancora adottato il prodotto.
COUNTRY_ID	Codice identificativo della nazione in cui l'HCP opera nell'ambito della campagna.
REGION	Regione di appartenenza della struttura di operatività dell'HCP.
CITY	Città in cui si trova la sede operativa dell'HCP per la campagna di riferimento.
BRICK	Codice/denominazione della micro-area geografica o sotto-distretto di vendita in cui è suddiviso il territorio aziendale (es. PAVIA 03).

Tabella 5: Campi della tabella `hcp_epi_in_scope_it`.

Seconda fase: pulizia dati mancanti o ridonanti

Successivamente alla selezione dei campi di interesse, l'analisi si è focalizzata sullo studio puntuale dei record all'interno della tabella.

Prima di procedere con la modellazione, si è reso necessario effettuare

un'operazione di pulizia per garantire l'integrità dei dati, verificando la presenza di record duplicati e di valori nulli (**NULL**).

Dall'analisi esplorativa è emerso che, in diversi campi, i valori mancanti non erano rappresentati dal classico **NULL** di sistema, bensì dal carattere speciale «?». Questa anomalia avrebbe compromesso sia la correttezza delle query SQL (invalidando le funzioni native di gestione dei valori nulli), sia la logica stessa dell'analisi, poiché il simbolo «?» viene interpretato come una stringa valida e non vuota. Perciò si è proceduto nel lavoro di sostituzione in **NULL** dei campi contrassegnati con «?».

Il controllo prioritario è stato eseguito sul campo **CONTACT_ID**: trattandosi della **chiave primaria**, è stato fondamentale assicurarsi che non vi fossero identificativi nulli o ridondanti. Eventuali record duplicati o privi di chiave primaria sono stati eliminati.

Per quanto riguarda i valori mancanti riscontrati in altri campi, si è deciso di non rimuoverli immediatamente, ma di conservarli temporaneamente per valutarne l'impatto e la gestione ottimale durante le successive fasi di *feature engineering*.

Terza fase: studio della tabella pulita

L'ultimo passaggio ha riguardato l'analisi descrittiva dei singoli campi che componevano la tabella. Per ciascuna colonna sono state eseguite operazioni di aggregazione (**GROUP BY**) e conteggio dei valori distinti, al fine di valutarne la distribuzione e la rilevanza analitica.

A tal fine, ci si è avvalsi dello strumento di data visualization interattiva **Databricks Genie**¹⁰ che opera all'interno delle *dashboard* native in Databricks.

L'impiego dei grafici si è rivelato fondamentale per comprendere la struttura del *dataset*, evidenziando trend, polarizzazioni e livelli di eterogeneità tra i gruppi di professionisti sanitari.

Dall'analisi esplorativa sono emerse le seguenti considerazioni sintetiche:

- **DIGITAL_ATTITUDE**: come evidenziato nella Figura 3, il parametro presenta una buona variabilità tra gli HCP, confermandosi una variabile importante da considerare nelle analisi successive;

¹⁰<https://docs.databricks.com/aws/en/genie>




Figura 3: Analisi distribuzione della *DIGITAL ATTITUDE*.

- **SEGMENTATION**: la Figura 4 mostra una discreta distribuzione ed eterogeneità tra le classi, rendendo la variabile utile per l'addestramento dei modelli;




Figura 4: Analisi distribuzione della *SEGMENTATION*.

- **SPECIALTY_ONEKEY_1_DESC**: la Figura 5 evidenzia una forte polarizzazione delle specializzazioni, legata alla natura specifica della campagna incentrata sull'epilessia;




Figura 5: Analisi distribuzione della *SPECIALTY*.

- **ADOPTION_LADDER**: presenta una distribuzione equilibrata tra i vari stadi di adozione del farmaco;
- **COUNTRY_ID**: privo di valore informativo ai fini della modellazione, in quanto costante su un unico Paese (Italia);
- **REGION**, **CITY**, **BRICK**: mostrano una buona distribuzione geografica, rivelandosi campi promettenti per le successive fasi di *feature engineering*.

3.2.2 Analisi tabelle delle azioni

Sono state esaminate tre tabelle contenenti lo storico delle diverse interazioni e azioni svolte con i professionisti sanitari:

1. **visit_epi_it**. Raccoglie lo storico completo delle visite svolte dai rappresentanti verso gli HCP presenti nella tabella anaagrafica;
2. **dem_epi_it**. In cui sono presenti tutti gli invii di comunicazioni DEM (*Direct Email Marketing*) e le relative interazioni effettuate da e verso gli HCP (es. aperture, click ecc.);
3. **rte_epi_it**. Analogamente al punto precedente traccia le comunicazioni di tipo RTE (*Real-Time Email*) ovvero le e-mail inviate direttamente dai rappresentanti farmaceutici.

Anche per questo gruppo di tabelle, le attività di pulizia e l'analisi esplorativa è stata suddivisa su più fasi.

Prima fase: comprensione del dominio e selezione delle colonne

L'attenzione si è inizialmente concentrata sulla comprensione del dominio concettuale dei singoli campi, avvalendosi del supporto e confronto con i referenti aziendali.

Una volta chiarita la semantica delle variabili, si è proceduto alla rimozione dei campi non rilevanti o ridondanti ai fini della modellazione. Le variabili selezionate per le tre tabelle sono riportate dettagliatamente nelle Tabella 6 per **visit_epi_it** e Tabella 7 per **dem_epi_it** e **rte_epi_it**.

Campo	Spiegazione
SLICE	Tipologia di interazione tracciata nel record (per questa tabella assume valore costante «VISIT»).

Campo	Spiegazione
KEY_COUNTRY_CONTACT	Chiave composta (prefisso COUNTRY_ID e CONTACT_ID) che costituisce la chiave esterna per collegare l'azione all'anagrafica dell'HCP.
DATE_SQL	Data e ora in cui è stata eseguita la visita.
CALL_TYPE	Il tipo di visita eseguita. Che si suddivide tra: • «<i>VisitF2F</i>»: interazione in presenza (<i>Face-to-Face</i>); • «<i>PhoneCall</i>»: contatto o colloquio telefonico; • «<i>VideoCall</i>»: interazione da remoto o in videoconferenza.
HAS_CLM	Flag binaria che indica l'impiego di CLM (<i>Closed-Loop Marketing</i>), ossia presentazioni digitali interattive a supporto del rappresentante: • 1: utilizzo di materiale CLM durante la visita; • 0: visita effettuata senza ausilio di CLM.
KEY_MESSAGES	Messaggi chiave presentati durante l'uso del CLM: • <u>nel caso di utilizzo di CLM</u> specifica il dettaglio della pagina/diapositiva mostrata (generando un record per ciascuna pagina vista); • <u>altrimenti</u> riporta il valore «-1»

Tabella 6: Campi della tabella **visit_epi_it**.

Campo	Spiegazione
SLICE	Canale di comunicazione a cui si riferisce il record (rispettivamente "DEM" o "RTE").
KEY_COUNTRY_CONTACT	Chiave esterna di collegamento con la tabella anagrafica degli HCP.
ACTION	Tipologia di interazione registrata sulla comunicazione e-mail, l'interazione può essere: • «<i>SENT</i>»: mail inviata con successo all'HCP; • «<i>OPEN</i>»: mail aperta dal destinatario; • «<i>CLICK</i>»: interazione con i link o contenuti presenti nel corpo della mail. <u>Solo per le comunicazioni RTE:</u> • «<i>BOUNCED</i>»: mancata consegna della mail (indirizzo non valido o errore di recapito).
DATE_SQL	Data e ora in cui si è verificata la specifica azione (« <i>ACTION</i> »).

Tabella 7: Campi delle tabelle `dem_epi_it` e `rte_epi_it`.

Seconda fase: pulizia dati

In questa fase sono stati condotti controlli analoghi a quelli descritti per la tabella anagrafica (Sezione 3.2.1), procedendo alla bonifica dei valori nulli e anomali.

Inoltre, si è resa necessaria una trasformazione specifica sulla chiave esterna `KEY_COUNTRY_CONTACT`. Per agevolare le successive operazioni di congiunzione (`JOIN`) tra le tabelle delle azioni e la tabella anagrafica, la colonna è stata ridenominata in `CONTACT_ID` e opportunamente manipolata tramite una stringa di taglio (Codice 2).

Originalmente, la variabile `KEY_COUNTRY_CONTACT` conteneva un prefisso numerico relativo al Paese, concatenato all'identificativo del contatto tramite un carattere di *underscore* (ad esempio, `3000008_CN605560-8V51-4667-9436-R7E5446799U9`). L'anagrafica riportava il campo `CONTACT_ID` con il solo codice identificativo dell'HCP (es. `CN605560-8V51-4667-9436-R7E5446799U9`). Si è pertanto estratta esclusivamente la componente alfanumerica successiva al separatore (*underscore*), garantendo la perfetta corrispondenza tra le chiavi.

```
TRIM(SUBSTRING(KEY_COUNTRY_CONTACT FROM
1 POSITION('_' IN KEY_COUNTRY_CONTACT) + 1)) AS CONTACT_ID,
```

SQL

Codice 2: Trim su ``KEY_COUNTRY_CONTACT``.

È stato inoltre riscontrato un disallineamento nei tipi di dato del campo `DATE_SQL`: in alcune tabelle la variabile era memorizzata sotto forma di stringa (sebbene rispettasse il formato temporale), mentre in altre era già definita come tipo di dato temporale. Si è quindi proceduto preventivamente alla loro uniformazione, convertendo tutte le colonne al tipo `TIMESTAMP`.

Successivamente, si è scelta la rimozione dell'informazione relativa all'orario, mantenendo la sola componente della data (`DATE`). Questa decisione è stata guidata da due considerazioni principali:

- **Assenza di valore informativo sulle visite:** dall'analisi esplorativa è emerso che tutti i record della tabella `visit_epi_it` riportavano come orario la mezzanotte precisa (`00:00:00`), segnato predefinito al momento della registrazione del dato;
- **Riduzione del rumore:** per le tabelle delle e-mail (`dem_epi_it` e `rte_epi_it`), data la quantità complessiva di record a disposizione, un livello di granularità orario avrebbe introdotto un'eccessiva *varianza_G*, fungendo da rumore nei modelli di apprendimento.

È opportuno precisare che la rinuncia al dettaglio orario rappresenta una scelta metodologica legata agli obiettivi e alla dimensione del dataset attuale; l'informazione oraria rimane un elemento potenzialmente utile per sviluppi futuri e modelli con una maggiore precisione.

In ultima battuta, si è deciso di unificare le tre tabelle delle azioni (`rte_epi_it`, `dem_epi_it` e `visit_epi_it`) all'interno di un unico dataset consolidato. Le colonne non presenti in tutte le tabelle sorgente

sono state conservate nello schema finale, popolandole con valori **NULL** per le tipologie di azione in cui non trovarono applicazione.

La scelta dell'unione è stata guidata da una motivazione metodologica: tutte e tre le sorgenti tracciano interazioni ed eventi direttamente afferenti al singolo HCP. Per poter studiare in modo organico l'attitudine del professionista sanitario e valutare la risposta alle diverse sollecitazioni, si è rivelato fondamentale disporre di una visione d'insieme dell'intero storico omnicanale.

A tale scopo è stata creata la tabella **clean_all_epi_it**, che accentra l'insieme delle interazioni svolte e costituisce la base dati primaria per la successiva fase di modellazione.

Terza fase: analisi esplorativa del dataset unificato (clean_all_epi_it)

Analogamente a quanto fatto per la tabella anagrafica, l'analisi esplorativa è stata condotta integrando i *notebook* di Databricks con gli strumenti di *Data Visualization* aziendali.

Dallo studio delle interazioni sono emerse le seguenti considerazioni sintetiche:

- **Sbilanciamento del canale RTE:** le comunicazioni di tipo **RTE** rappresentano soltanto il 6,84% del totale delle azioni (Figura 6). Pur riflettendo la realtà operativa (in cui gli invii personalizzati dei REP sono quantitativamente inferiori alle campagne massive), questo sproporzionato volume (*class imbalance*) costituisce una criticità per i futuri algoritmi di *Machine Learning*, che potrebbero faticare a trarre pattern significativi o scartare la variabile;




Figura 6: Analisi distribuzione delle possibili azioni.

- **Polarizzazione delle interazioni e-mail:** come evidenziato nella Figura 7, le azioni sulle mail sono polarizzate sullo stadio di invio (SENT). Si riscontra inoltre la presenza di un numero non trascurabile di eventi BOUNCED (indirizzi non raggiungibili). Confrontando le campagne **DEM** (Figura 9) e **RTE** (Figura 8), il trend rimane analogo (prevalenza di **SENT**), ad eccezione del tasso di CLICK, proporzionalmente più elevato negli RTE: questo comportamento rispecchia la natura personalizzata del canale diretto;




Figura 7: Analisi distribuzione delle azioni digitali.




Figura 8: Analisi distribuzione delle azioni tra gli RTE nel tempo.




Figura 9: Analisi distribuzione delle azioni tra i DEM nel tempo.

- **Predominanza e disallineamento temporale delle visite:** le visite tradizionali (Figura 10) mostrano una marcata preferenza per la modalità in presenza (Face-to-Face), la quale copre circa l'87,80% delle 42.392 interazioni registrate. Tuttavia, dall'analisi temporale (Figura 11) emerge un disallineamento strutturale: i dati sulle visite in presenza partono da inizio 2019, mentre le altre tipologie di visita registrano eventi solo a partire da fine 2019/inizio 2020;




Figura 10: Analisi distribuzione delle azioni tra le visite.




Figura 11: Analisi distribuzione delle azioni tra le visite nel tempo.

- **Disallineamento temporale macro-canale (*Digital vs F2F*):** il divario temporale appare ancora più evidente nell'analisi aggregata delle macro-azioni (Figura 12). Mentre lo storico delle visite gestite dai REP copre l'intero intervallo a partire dal 2019, i canali digitali (DEM e RTE) presentano volumi solo a partire da metà 2022. Questa asimmetria di circa due anni e mezzo attribuisce un peso sproporzionato al canale fisico rispetto a quello digitale, potendo introdurre un *bias* nelle analisi storiche di ingaggio.




Figura 12: Analisi distribuzione delle azioni nel tempo.

3.3 Profilazione della *digital attitude* tramite Clustering

Entrando nel vivo del progetto, si passa alla fase di profilazione degli HCP in base all'attitudine digitale degli stessi.

A questo scopo la richiesta è stata quella di creare un modello di *Clustering* che potesse supportare la richiesta.

In accordo con le linee guida espresse dal team aziendale, l'algoritmo individuato per la profilazione è stato il **K-Means**.

Sono stati comunque presi in considerazione più algoritmi di *Clustering* non supervisionato, valutandone l'applicabilità al caso di studio:

- **Clustering Gerarchico_G**: è stato immediatamente scartato a causa dell'elevata complessità computazionale ($\mathcal{O}(n^3)$ nel caso generale o $\mathcal{O}(n^2)$ nelle versioni ottimizzate). Rispetto a questo, il K-Means garantisce una complessità lineare $\mathcal{O}(n \cdot k \cdot i \cdot d)$, risultando nettamente più efficiente e scalabile;
- **DBSCAN_G**: questo approccio basa la clusterizzazione sul concetto di *Nearest Neighbor* e sulla densità locale, identificando i gruppi senza imporre un numero fisso di cluster e classificando i punti isolati come *outlier*. Tuttavia, per garantire la stabilità e la riuscita della segmentazione aziendale, si è preferito un modello basato su **centroidi** (K-Means).

Il principale discriminante metodologico risiede nella possibilità di determinare e controllare preventivamente un numero di cluster k «sicuro» e ben definito tramite l'esame dell'*Elbow Method* (spiegato nella Sezione 3.3.3).

Queste motivazioni, unite alla necessità aziendale di assegnare ogni singolo HCP a un profilo e di disporre di una metodologia facilmente interpretabile, ha confermato il K-Means come la scelta ottimale per il progetto.

3.3.1 K-Means: fondamenti teorici

Il K-Means è un algoritmo di partizionamento non supervisionato che ha lo scopo di suddividere un insieme di n osservazioni $X = \{x_1, x_2, \dots, x_n\}$ in k cluster distinti $C = \{C_1, C_2, \dots, C_k\}$, dove **k rappresenta un iperparametro prefissato**.

Matematicamente, l'algoritmo mira a minimizzare la varianza interna ai cluster, nota come *Within-Cluster Sum of Squares* (WCSS) o **inerzia_G**, definita dalla seguente funzione obiettivo:

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

dove μ_i rappresenta il **centroide** (il punto medio) del cluster C_i , e $\|x - \mu_i\|^2$ indica la distanza euclidea al quadrato tra l'osservazione x e il centroide μ_i .

L'algoritmo opera attraverso un processo iterativo ben definito.

Nella fase iniziale di **inizializzazione**, vengono individuati k punti nello spazio delle **feature** da assumere come centroidi di partenza $\mu_1, \dots, \mu_k$.

Successivamente, nella fase di **assegnazione**, ciascuna osservazione x_j viene associata al cluster il cui centroide risulta geometricamente più vicino secondo la distanza euclidea:

$$C_i = \{x_j : \|x_j - \mu_i\| \leq \|x_j - \mu_l\| \quad \forall l, 1 \leq l \leq k\}$$

A questo punto si passa alla fase di **aggiornamento**, in cui viene ricalcolata la posizione di ciascun centroide μ_i come media aritmetica di tutte le osservazioni correntemente assegnate a quel determinato gruppo:

$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$$

Infine, nella fase di **convergenza**, i passaggi di assegnazione e aggiornamento vengono ripetuti ciclicamente fino a quando la posizione dei centroidi non varia più in modo significativo, ovvero fino a quando lo scostamento dell'inerzia J scende sotto una soglia di tolleranza ε prestabilita, o al raggiungimento del numero massimo di iterazioni consentite.

3.3.2 Feature Engineering per la misura dell'attitudine digitale

A partire dal dataset consolidato `clean_all_epi_it`, la fase di *Feature Engineering* è stata progettata per trasformare le interazioni puntuali degli HCP in variabili sintetiche relative a una finestra temporale recente di 120 giorni, questo per garantire che i cluster siano aggiornati relativamente agli ultimi atteggiamenti digitali degli HCP e non abbiano *bias* relativi ai comportamenti molto vecchi degli stessi.

La finestra temporale, in ogni caso, può essere facilmente ampliata o diminuita.

La logica implementata adotta un **approccio ibrido**: prima di somministrare i dati all'algoritmo di *Machine Learning*, si applica una segmentazione deterministica (*Rule-Based*) per escludere o etichettare le casistiche aziendali che non richiedono o non possono beneficiare dell'algoritmo di *clustering* e rischierebbero altrimenti di creare rumore all'interno del modello.

3.3.2.1 Regole deterministiche

Tramite query SQL e metriche di *Recency* e *Frequency*, ciascun HCP viene analizzato e categorizzato in quattro gruppi principali:

- **UNTOUCHED/NEW-EXPLORATION**: identifica i medici mai contattati o per i quali non figura alcuna interazione registrata nello storico;
- **INACTIVE/DORMANT**: racchiude gli HCP che non hanno registrato alcuna attività negli ultimi 120 giorni;
- **BOUNCED/INVALID**: individua i contatti con problemi di raggiungibilità sul canale e-mail, definiti da una soglia critica di *bounce* registrati nell'ultimo quadrimestre ($DEM_Bounce_120gg \geq 5$);
- **ELIGIBLE_FOR_ML**: include tutti gli HCP attivi che non ricadono nelle categorie precedenti. Solo questa coorte viene fatta proseguire verso la successiva fase di calcolo delle *feature* ed elaborazione da parte del K-Means.

3.3.2.2 Ingegnerizzazione delle *feature* per il *Machine Learning*

Per gli HCP appartenenti alla classe **ELIGIBLE_FOR_ML**, il codice calcola un set di *feature* derivate e normalizzate tramite funzioni PySpark. Tali variabili mirano a catturare l'intensità di ingaggio, la preferenza di canale e la reattività digitale e sono presentati in Tabella 8.

Feature	Descrizione
<i>Monthly Interaction Intensity</i>	Volume medio mensile di interazioni totali sostenute dall'HCP (somma di contatti digitali e visite sul territorio, normalizzata sui quattro mesi della finestra analizzata).
<i>Digital Open Rate</i>	Percentuale di e-mail aperte rispetto al totale degli invii ricevuti. Per mitigare anomalie di tracciamento o aperture multiple, il valore viene limitato a un tetto massimo del 100% (1.0).
<i>Share of F2F</i>	Peso percentuale delle visite fisiche in presenza (<i>Face to Face</i>) sul totale delle interazioni svolte dai rappresentanti sul territorio.

Feature	Descrizione
<i>Share of Remote</i>	Quota percentuale di visite effettuate a distanza via <i>Remote Call</i> sul totale delle visite territoriali.
<i>Digital Engagement Rate</i>	Qualità dell'interesse digitale dell'HCP, definita come la percentuale di e-mail che hanno generato un click sul totale delle e-mail effettivamente aperte.
<i>Share of Digital</i>	Inclinazione al macro-canale del medico, ovvero la percentuale di interazioni digitali (aperture DEM e RTE) sul totale complessivo delle interazioni ricevute (digitali + visite);
<i>RTE Preference Ratio</i>	Preferenza relativa all'interno del canale e-mail, misurando la quota di aperture di mail inviate direttamente dal REP (RTE) rispetto al totale delle aperture digitali (RTE + DEM).

Tabella 8: Feature individuate per l'algoritmo di clustering.

«*Nota metodologica sulla multicollinearità*: la quota delle chiamate telefoniche (*Phone Call*) non è stata inserita intenzionalmente come variabile indipendente per evitare problemi di multicollinearità perfetta nei modelli, essendo linearmente dipendente dalle altre due modalità sul territorio (*Face to face* e *Remote Call*).»

Le variabili così ingegnerizzate vengono infine salvate in modalità nella tabella di *staging* Delta `stg_segmentation_raw_features`, pronta per essere sottoposta alle successive fasi di *scaling*/standardizzazione e segmentazione via K-Means.

3.3.3 Implementazione, addestramento e valutazione del modello

3.3.3.1 Implementazione

La seconda macro-fase della pipeline riguarda l'addestramento dell'algoritmo di *clustering*, la mappatura logico-commerciale dei gruppi ottenuti e il calcolo delle metriche di comportamento temporale (latenza).

I dati appartenenti alla coorte **ELIGIBLE_FOR_ML** vengono convertiti in ambiente Pandas per l'elaborazione vettoriale. Prima della somministrazione all'algoritmo, si procede alla normalizzazione tramite **StandardScaler**, la quale trasforma ciascuna variabile affinché abbia media nulla e varianza unitaria.

Successivamente, per rispondere a precise direttive di strategia *omni-channel* è stata applicata una **pesatura differenziata** (+50%) su due variabili chiave:

- **Share_of_F2F**: incrementata del fattore 1.5 per dare maggior risalto al canale in presenza;
- **Share_of_Digital**: incrementata del fattore 1.5 per enfatizzare la reattività complessiva al canale digitale.

Tale pesatura consente di guidare lo spazio delle distanze euclidee, forzando l'algoritmo a separare in modo più netto i profili fisici da quelli digitali.

3.3.3.2 Addestramento

Prima di procedere all'addestramento, l'iperparametro k (il numero finale di *cluster*) è stato individuato in modo analitico tramite l'**Elbow Method** (Metodo del Gomito) in Figura 13.

«*Come funziona l'Elbow Method*: si esegue l'algoritmo K-Means per un intervallo di valori di k (in questo caso da 1 a 14), calcolando per ciascuna iterazione l'inerzia, ovvero la somma delle distanze al quadrato tra ogni punto e il relativo centroide.

Graficando il valore dell'inerzia in funzione di k , la curva decresce monotonicamente: all'aumentare dei cluster, i punti sono più vicini ai centroidi. Il valore ottimale di k corrisponde al punto di flesso della curva (il «gomito»), ovvero la soglia oltre la quale l'aggiunta di un ulteriore cluster porta a una riduzione trascurabile dell'inerzia, evitando sia il *underfitting* sia il *overfitting* della segmentazione.»




Figura 13: Analisi sulla scelta di k utilizzando l'*Elbow Method*.

La scelta è confluita in $k = 8$, sia grazie all'analisi del grafico dell'*Elbow Method* (Figura 13) sia perché, in ottica aziendale, questo numero di segmenti è risultato il più fluido e gestibile per le strategie di business.

Il modello K-Means viene addestrato sulle *feature* scalate e pesate attraverso il l'algoritmo di *clustering* (Codice 3).

```

1  from sklearn.cluster import KMeans
2
3  # Definizione del numero di cluster ottimale
4  k_ottimale = 8
5
6  # Inizializzazione e addestramento del modello K-
  Means
7  kmeans_final = KMeans(
8      n_clusters=k_ottimale,
9      random_state=42,
10     n_init=10
11 )
12
13 # Assegnazione dei cluster ai dati scalati e pesati
14 pdf_features['ML_Cluster_Raw'] =
  kmeans_final.fit_predict(X_scaled_final)

```

Codice 3: Implementazione essenziale modello K-Means utilizzato.

3.3.3.3 Risultati del modello

I cluster numerici generati dal modello (0...7) sono stati sottoposti ad un processo di **mappatura supervisionata**, volto a tradurre le proprietà matematiche dei gruppi in segmenti commerciali e operativi.

A tal fine, sono state calcolate le medie reali delle *feature* (i centroidi) per ciascuno degli 8 *cluster* attivi, la cui distribuzione percentuale (relativa a metriche quali **Digital_Open_Rate**, **Share_of_F2F** e **RTE_Preference_Ratio**) è stata visualizzata graficamente tramite la *heatmap* comportamentale (Figura 14), generata in Python mediante le librerie **seaborn** e **matplotlib**.

Questa rappresentazione a matrice consente di identificare a colpo d'occhio i tratti distintivi di ciascun gruppo, garantendo al contempo la validazione della segmentazione attraverso la verifica dell'assenza di sovrapposizioni o ridondanze tra i profili creati.




Figura 14: *Heatmap* derivata dall'algoritmo k-Means.

L'esame incrociato delle metriche percentuali ha permesso di definire l'identità operativa di ciascun gruppo. I dettagli e le descrizioni operative dei segmenti individuati sono riassunti nella Tabella 9.

N° Cluster	Cluster	Descrizione
0	Omnichannel VIPs	Elevatissima ricettività digitale con un <i>Digital Open Rate</i> pari al 96%, abbinata a un solido ingaggio sul territorio (<i>Share of F2F</i> al 78%) e a una marcata quota digitale complessiva (59%).
1	Traditional F2F	Profilo puramente fisico, dominato da una <i>Share of F2F</i> del 94% e tassi di ingaggio digitale prossimi allo 0%.
2	Digital-First /Mail-Only	Nettissima prevalenza del canale digitale (<i>Share of Digital</i> al 92%) e un'ottima apertura e-mail (65%), in totale assenza di interazioni in presenza (0% F2F).
3	Science-Oriented (Passive)	Bilanciamento tra visite fisiche (92% F2F) e comunicazioni e-mail fortemente orientate ai contenuti d'informazione scientifica remota (<i>RTE Preference Ratio</i> al 94%).
4	Promo-Oriented (Passive)	Elevato ingaggio sul territorio (99% F2F) unito a una spiccata propensione all'apertura delle e-mail di prodotto o promozionali (75% <i>Open Rate</i> , con bassa preferenza RTE).

N° Cluster	Cluster	Descrizione
5	Digital Advocates (Top Responders)	Il segmento a più alto valore qualitativo sul digitale, registrando l'unico valore di <i>Digital Engagement Rate</i> (click) rilevante dell'intero campione (91%), unito a un'alta preferenza per comunicazioni scientifiche (88%).
6	Phone-Centric	Profili con valori mediamente bassi o moderati su tutti i canali principali, gestiti prevalentemente tramite contatto telefonico.
7	Virtual-Friendly (Video-Call Lovers)	Si distingue nettamente da tutti gli altri gruppi per l'eccezionale concentrazione di visite via <i>Remote Call</i> (<i>Share of Remote</i> al 71%).

Tabella 9: Cluster individuati dal k-Means.

Parallelamente, i dati relativi ai medici precedentemente esclusi dall'algoritmo di *Machine Learning* vengono recuperati e ricondotti a tre segmenti statici di business: *Onboarding (Exploration)* per i nuovi o non contattati, *Unreachable/Tech Issue* per i contatti con problemi di recapito (*bounced*), e *Dormant* per i medici inattivi negli ultimi 120 giorni.

Il dataset completo viene consolidato e persistito nella tabella Delta `hcp_final_segmentation`.

Infine, gli oggetti di trasformazione e modellazione (`StandardScaler` e il modello K-Means addestrato) vengono serializzati e salvati nei *Volumes* di *Unity Catalog*. Tale approccio garantisce la riproducibilità e la *governance dei modelli*, consentendo di riutilizzarli in fase di *inference* su nuovi dati senza dover riaddestrare la rete.

3.3.4 Valutazione dei risultati

Per interpretare la rilevanza delle singole variabili nelle decisioni di partizione del K-Means, è stato addestrato un modello surrogato *Random Forest Classifier* sugli stessi dati di input.

L'analisi dell'indice di importanza delle *feature* (in Figura 15) rivela che:

- *Share of Digital* (circa 18%), *RTE Preference Ratio* (circa 17%) e *Monthly Interaction Intensity* (circa 17%) rappresentano i tre fattori di maggior peso decisionale. La marcata rilevanza di *Share of Digital* valida l'efficacia della pesatura strategica (+50%) applicata in fase di pre-elaborazione;
- *Share of F2F* (17%) e *Digital Open Rate* (15.5%) forniscono un contributo determinante nel separare i medici a vocazione prevalentemente fisica da quelli ricettivi via mail;
- *Digital Engagement Rate* (8.7%) e *Share of Remote* (3.3%) agiscono come *feature* di affinamento per isolare nicchie specifiche (come i *Digital Advocates* o i *Video-Call Lovers*).




Figura 15: Importanza delle feature usate dall'algoritmo k-Means

L'analisi quantitativa condotta sul campione totale di 702 HCP (comprendente gli 8 cluster dinamici da K-Means e le categorie statiche) evidenzia una struttura di popolazione estremamente bilanciata e coerente con la realtà di mercato, si può leggere in Figura 16.




Figura 16: Distribuzione dei cluster sul dataset.

Il core della popolazione aziendale è costituito dai segmenti *Science-Oriented (Passive)* (25.6%), *Traditional F2F* (22.8%) e *Promo-Oriented (Passive)* (19.8%).

Gli *Omnichannel VIPs* rappresentano un gruppo ad alto valore strategico (12.7%).

I segmenti digitali avanzati o di nicchia comprendono i *Digital Advocates*, i *Phone-Centric*, i *Digital-First/Mail-Only* e i *Virtual-Friendly*. Infine, i gruppi statici di esclusione contano *Dormant* e *Unreachable*.

3.4 Modellazione predittiva per la Next Best Action (NBA)

Per la generazione dei suggerimenti relativi all'azione ottimale da intraprendere nei confronti di ciascun HCP (*Next Best Action*), è stato condotto uno studio e sperimentazione sulle metodologie disponibili.

Inizialmente, l'obiettivo si è focalizzato sulla valorizzazione dei segmenti comportamentali appena individuati, valutando la possibilità di riutilizzare il set di *feature* ingegnerizzate per la profilazione anche ai fini della predizione della *Next Best Action*.

In questo contesto preliminare, l'esplorazione si è sviluppata lungo due direttrici metodologiche principali:

- Catene di Markov (*Markov Chains*);
- Algoritmi basati su Gradient Boosting_G (*CatBoost* e *LightGBM*).

Di seguito vengono analizzate nel dettaglio le due famiglie di algoritmi, illustrando le criticità teoriche e pratiche emerse dai primi test che ne hanno determinato lo scarto nella loro formulazione iniziale, ponendo le basi per la re-ingegnerizzazione del problema e la scelta della soluzione finale basata su ***Gradient Boosting con LightGBM***.

3.4.1 Sperimentazione con le *Markov Chains*

Nel primo esperimento applicativo, si è tentato di modellare la generazione della *Next Best Action* attraverso un sistema *stocastico_G* basato sulle Catene di Markov (*Markov Chains*).

Una **Catena di Markov di primo ordine** è un processo stocastico a tempo discreto in cui la probabilità di passare allo stato futuro $X_{\{t+1\}}$ dipende esclusivamente dallo stato presente X_t , ignorando la storia passata (assenza di memoria o **Proprietà di Markov**):

$$P(X_{\{t+1\}} = j \mid X_t = i, X_{\{t-1\}} = i_{\{t-1\}}, \dots, X_0 = i_0) = \\ P(X_{\{t+1\}} = j \mid X_t = i) = p_{\{ij\}}$$

Come illustrato in Figura 17, la dinamica può essere rappresentata tramite un grafo orientato pesato o una matrice di transizione stocastica P , dove la somma delle probabilità in uscita da ogni stato è pari a 1.




Figura 17: Esempio catena di Markov.¹¹

Per superare la rigidità della memoria a singolo passo, si definisce **Catena di Markov di ordine m** (con $m > 1$) un modello in cui lo stato futuro $X_{\{t+1\}}$ dipende dagli ultimi m stati della sequenza temporale:

$$P(X_{\{t+1\}} \mid X_t, X_{\{t-1\}}, \dots, X_0) = P(X_{\{t+1\}} \mid X_t, X_{\{t-1\}}, \dots, X_{\{t-m+1\}})$$

Sebbene questo approccio ampli la finestra di memoria locale, esso comporta una crescita esponenziale dello spazio degli stati ($|S|^m$), aumentando la rigidità del modello di fronte a sequenze poco frequenti o non osservate nello storico.

3.4.1.1 Analisi e criticità delle Catene di Markov

Nel contesto del progetto, si è pensato di adattare questo quadro teorico definendo uno spazio degli stati finito S corrispondente alle tipologie di azione eseguibili nei confronti dell'HCP:

$$S = \{\text{Face to Face, Video Call, Phone Call, Send DEM, Send RTE}\}$$

Per ciascuno degli 8 *cluster* identificati nella fase di *clustering*, si è pensato di costruire una specifica matrice di transizione delle probabilità $P^{\{(k)\}}$, derivata dalla distribuzione empirica delle *feature* comportamentali.

¹¹Fonte: Joxemai4 - Own work, CC BY-SA 3.0.

Per rendere la rete maggiormente dinamica e aderente al contesto aziendale, si voleva integrare il modello con:

1. **Moltiplicatori di peso** basati sull'attitudine digitale dell'utente (**DIGITAL_ATTITUDE**);
2. Una funzione di **Reward** (ricompensa) calibrata sulla segmentazione di business dell'HCP;
3. Un'estensione dell'ordine della catena (*High-Order Markov Chain*), configurata per considerare gli ultimi 3 stati storici registrati dall'HCP ($S_{\{t-2\}}, S_{\{t-1\}}, S_t$), al fine di guidare la decisione della transizione successiva $S_{\{t+1\}}$.

Nonostante i tentativi di arricchimento contestuale, **l'approccio è stato formalmente scartato** in accordo con i referenti aziendali, per le seguenti motivazioni:

- Natura eccessivamente stocastica/probabilistica: la matrice di transizione tendeva a suggerire azioni basate su frequenze statistiche aggregate, faticando a catturare i pattern individuali o le anomalie comportamentali del singolo medico.
- Limite strutturale della Proprietà di Markov: sebbene l'estensione ad un ordine superiore ($p = 3$) tentasse di mitigare l'assenza di memoria, la natura essenzialmente «locale» del modello si è dimostrata un limite invalidante. L'evoluzione della relazione tra il REP e l'HCP richiede la valutazione dell'intero storico longitudinale del contatto (es. latenze sul lungo periodo, stagionalità, trend di reattività).
- Incapacità di generalizzazione: il modello risultava rigido e poco incline ad adattarsi rapidamente a repentini cambi di ingaggio dell'HCP senza dover ricalcolare interamente le matrici di probabilità.

Si è dunque deciso di abbandonare i modelli stocastici di transizione in favore di un approccio di Machine Learning classico con apprendimento supervisionato.

3.4.2 Sperimentazione con il *Gradient Boosting*

L'attenzione si è spostata sulla famiglia degli algoritmi di *Gradient Boosting*, riconosciuti per le prestazioni su dati strutturati e tabulari.

Il **Gradient Boosting** è una tecnica di apprendimento supervisionato basata sul principio del *boosting*: una sequenza di modelli predittivi deboli (tipicamente alberi di decisione di ridotta profondità) viene combinata per costruire un modello predittivo forte.

L'addestramento avviene in modo sequenziale. Ogni nuovo albero $h_{m(x)}$ viene addestrato per stimare i residui (ovvero l'errore) commessi

dai modelli precedenti, muovendosi lungo la direzione del gradiente negativo della funzione di perdita $L(y, f(x))$.

Analiticamente, dato un dataset $\{(x_i, y_i)\}_{i=1}^N$, l'obiettivo è trovare una funzione $F(x)$ che minimizzi il valore atteso della funzione di perdita:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x)$$

dove γ_m rappresenta il passo di apprendimento (*learning rate*) e $h_{m(x)}$ è il nuovo albero addestrato sugli pseudo-residui r_{im} :

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)}$$

3.4.2.1 *CatBoost*: fondamenti teorici

Tra i diversi framework di Gradient Boosting, il primo ad essere preso in considerazione è stato CatBoost (*Categorical Boosting*), sviluppato da Yandex¹². La scelta iniziale è stata dettata da due caratteristiche strutturali distintive dell'algoritmo:

1. Gestione nativa delle feature categoriche: CatBoost evita le trasformazioni tradizionali (come One-Hot Encoding_G o Label Encoding_G) convertendo le categorie in valori numerici. Per prevenire il fenomeno del *target leakage* (in cui il valore target di un record influenza la propria stessa feature), l'algoritmo applica una permutazione casuale dell'intero *dataset*: per ogni record, la stima della categoria viene calcolata considerando unicamente i valori target delle osservazioni che lo precedono in quel determinato ordine simulato.
2. Alberi Simmetrici (*Oblivious Trees*): a differenza di altri algoritmi di boosting che valutano criteri di split differenti per ciascun nodo e fanno crescere gli alberi foglia per foglia, CatBoost seleziona un *unico criterio di split globale* per ciascun livello. Questa condizione viene applicata uniformemente a tutti i nodi dello stesso livello, costringendo l'albero a crescere in modo perfettamente bilanciato e simmetrico.

Questa simmetria strutturale garantisce un'elevata regolarizzazione dell'algoritmo, riducendo il rischio di *overfitting* e stabilizzando la struttura del modello.

¹²<https://catboost.ai>

3.4.2.1.1 Esperimenti condotti e analisi delle criticità

Nel primo approccio sperimentale, si è tentato di sfruttare di CatBoost per predire la *Next Best Action* addestrando il modello direttamente sulle categorie native a disposizione, quali i segmenti di clustering recentemente identificati, le tipologie di interazione storica e le variabili aziendali preesistenti (**DIGITAL_ATTITUDE**, **SEGMENTATION** ecc.). Sono state condotte diverse prove sia utilizzando i dati in formato grezzo, sia applicando un primo livello di *feature engineering*.

Tuttavia, l'analisi approfondita dei risultati ha portato a scartare CatBoost in favore di altre soluzioni, a causa di alcune criticità operative e strutturali.

Nonostante la dimensione contenuta del dataset a disposizione per gli esperimenti, CatBoost ha mostrato **tempi di esecuzione e di addestramento elevati**. Sebbene tali tempistiche potessero essere parzialmente tollerabili in fase di ricerca preliminare, l'algoritmo è risultato non idoneo alle logiche di un processo aziendale quasi quotidiano o con esigenze di inferenza istantanea.

In secondo luogo, con il progredire della fase di *feature engineering*, si è notato come il **dataset finale non fosse più dominato da variabili puramente categoriali**. L'estrazione di metriche quantitative ha sbilanciato la matrice dei dati a favore di *feature* numeriche continue.

Tali evidenze hanno condotto il team ad abbandonare l'approccio con CatBoost, riorientando la ricerca verso la libreria **LightGBM**.

3.4.3 Predizione NBA: *Gradient Boosting con LightGBM*

A seguito delle limitazioni riscontrate con le Catene di Markov e con l'approccio basato su CatBoost, la ricerca metodologica si è orientata verso **LightGBM** (*Light Gradient Boosting Machine*), un *framework* di *Gradient Boosting* sviluppato da Microsoft¹³.

LightGBM ottimizza l'efficienza computazionale, la velocità di addestramento e il consumo di memoria, garantendo al contempo un'elevata accuratezza predittiva grazie a due innovazioni algoritmiche:

1. GOSS (Gradient-based One-Side Sampling): poiché i dati con un gradiente più elevato contengono più informazione (rappresentano le istanze che il modello sbaglia di più), GOSS evita di dover elaborare tutti i dati a ogni iterazione: *mantiene tutti i dati a gradiente elevato*, ovvero i record più «difficili» e informativi; *esegue un campionamento*

¹³<https://www.microsoft.com/it-it>

casuale solo su una percentuale dei dati a basso gradiente (già ben addestrati) e *riconfigura i pesi* dei dati a basso gradiente tenuti nel calcolo, garantendo che la stima del guadagno d'informazione rimanga statisticamente corretta e non distorta.

2. EFB (Exclusive Feature Bundling): negli scenari ad alta dimensionalità (particolarmente frequenti dopo la fase di *feature engineering*), molte variabili risultano mutualmente esclusive (raramente assumono valori diversi da zero simultaneamente). Tali *feature* sparse e mutualmente esclusive vengono raggruppate in un unico «pacchetto» (*bundle*), riducendo la dimensionalità della matrice delle feature senza alcuna perdita tangibile di informazione.

Un'ulteriore distinzione chiave risiede nella strategia di costruzione degli alberi di decisione. La maggior parte degli algoritmi di boosting tradizionali (incluso *XGBoost*¹⁴) adotta una crescita *level-wise* (o *depth-wise*), espandendo l'albero livello per livello.

LightGBM utilizza invece una strategia di crescita *leaf-wise* (foglia per foglia) con vincolo sulla profondità massima.




Figura 18: Confronto tra strategia di crescita Leaf-wise (a sinistra) e Level-wise (a destra).¹⁵

A ogni passo, l'algoritmo valuta tutte le foglie esistenti e sceglie di dividere unicamente la singola foglia che garantisce la massima riduzione della funzione di perdita (massimo guadagno d'informazione).

Questa crescita asimmetrica consente a LightGBM di raggiungere un errore di addestramento inferiore a parità di numero di split. Sebbene la crescita *leaf-wise* presenti un rischio teorico maggiore di *overfitting* su dataset ridotti, tale fenomeno viene mitigato attraverso il controllo della profondità massima dell'albero (`max_depth`) e del numero minimo di record per foglia (`min_child_samples`).

¹⁴<https://xgboost.ai>

¹⁵Fonte: Bzubeda, 'Machine Learning 101', Medium, Gennaio 2024

3.4.3.1 Data preparation & engineering

Per poter addestrare un modello dinamico come LightGBM capace di suggerire la *Next Best Action*, si è resa necessaria una complessa fase di trasformazione e ristrutturazione dei dati aziendali transazionali.

Il processo ha integrato la costruzione di una griglia temporale giornaliera, l'estrazione di *feature* di sequenza storica, il calcolo delle latenze e la definizione di metriche statiche e dinamiche di affinità per ciascun HCP.

I dati di partenza si presentavano sotto forma di registro di eventi disaccoppiati.

Per convertire tale struttura in una serie storica idonea al tracciamento delle interazioni è stato identificato il range temporale tra la prima interazione registrata per ciascun HCP e la data massima globale dell'intero dataset. Tramite una funzione di sequenza temporale (**F.sequence**), il *dataset* è stato esploso in modo da ottenere esattamente una riga per ogni giorno e per ogni medico. Nei giorni in cui non è stata registrata alcuna sollecitazione commerciale, l'azione è stata codificata come **NO_ACTION**.

Come eredità concettuale derivata dai primi esperimenti con le *Catene di Markov di terzo ordine*, si è deciso di preservare l'informazione storica relativa agli ultimi tre contatti. Utilizzando finestre temporali applicate unicamente alle giornate di interazione effettiva, sono state estratte le ultime 3 azioni commerciali reali eseguite dal REP su ciascun medico ($\text{lag}_1, \text{lag}_2, \text{lag}_3$). Tali variabili sono state successivamente propagate sui giorni di **NO_ACTION**, formando la variabile categoriale di sequenza **story_state** (es. **SendDEM_VisitF2F_SendRTE**).

Infine, per valutare l'efficacia del contatto, è stata definita una finestra prospettica di 7 giorni ($t \dots t + 7$). L'esito reale (**esito_reale**) è stato categorizzato in:

- **VISIT_EXECUTED**: per le visite condotte sul territorio;
- **CLICK** o **OPEN**: se nei 7 giorni successivi all'invio di un canale digitale (DEM o RTE) è stato registrato un segnale di ingaggio attivo;
- **NO_RESPONSE**: in assenza di reazioni da parte dell'HCP nello stesso intervallo.

Sono inoltre state calcolate diverse metriche di affinità individuale (Tabella 10), applicando tecniche di imputazione distribuita basate sui cluster di appartenenza.

Nome	Descrizione
Ratio Storici di Utilizzo	Per ogni HCP sono stati calcolati i tassi reali di ingaggio, tra cui la proporzione di visite F2F condotte con supporto di presentazioni digitali CLM (<code>clm_f2f_ratio</code>), nonché i tassi di <i>Click Rate</i> storici per i canali DEM (<code>dem_click_ratio</code>) ed RTE (<code>rte_click_ratio</code>).
Indici di Affinità di Canale:	Combinando la quota totale di ingaggio digitale (Share of Digital) e le preferenze storiche per canale (RTE Preference Ratio, Share of F2F, Share of Remote), sono stati sintetizzati indici numerici continui di affinità condizionata per i canali d'ingaggio. $\text{Affinity_SendRTE} = \text{Quota_Digital} \times \text{RTE_Preference_Ratio}$ $\text{Affinity_SendDEM} = \text{Quota_Digital} \times (1 - \text{RTE_Preference_Ratio})$
Regole Aziendali (<i>Business Rules</i>)	Per garantire che i medici appartenenti a cluster con forti anomalie di contatto o problemi tecnici venissero gestiti in sicurezza dal modello, sono stati applicati <i>override</i> deterministici dei valori di affinità per i gruppi «Unreachable/Tech Issue», «Onboarding (Exploration)» e «Dormant».
Giorni dall'Ultimo Contatto	Calcolati come la distanza in giorni tra la data corrente t e la data del contatto reale precedente.
Distanza e Rapporto di Latenza	La variabile temporale «Giorni dall'Ultimo Contatto» è stata messa in relazione diretta con la latenza mediana del cluster di appartenenza.

Tabella 10: Feature di preparazione ai modelli predittivi.

Tutti i dataframe transazionali, le sequenze e i profili statici arricchiti sono stati infine consolidati tramite join strutturate sulla chiave primaria **CONTACT_ID** e salvati stabilmente nell'architettura *Lakehouse* di Databricks come tabella Delta.

3.4.3.2 Addestramento del classificatore

L'obiettivo del motore di raccomandazione NBA è duplice: suggerire al REP il canale di contatto ideale per ogni medico (HCP) e fornire un indice di saturazione (che indica quanto sia opportuno agire).

Inizialmente si è testato un singolo classificatore multiclasse istruito per predire sia l'inazione (**NO_ACTION**) sia i canali attivi (**VisitF2F**, **SendDEM**, ecc.).

Tuttavia, la griglia temporale giornaliera generava una fortissima prevalenza di giornate senza contatto: la classe **NO_ACTION** superava l'80% del totale. Il modello monolitico ha così «imparato» a minimizzare la funzione di perdita predicendo quasi sempre l'inazione. Nonostante un' $Accuracy_G$ apparente dell'80%, il sistema risultava passivo e privo di capacità prescrittiva.

Per superare questo limite, il problema è stato decomposto in due modelli sequenziali e condizionati:

1. **Modello 1 — Predittore di Innesco e Saturazione (Binario):**
stima la probabilità che per l'HCP i al giorno t sia opportuno un contatto rispetto al riposo:

$$P(Y_{i,t} = \text{ACTION} \mid \mathbf{X}_1)$$

2. **Modello 2 — Selettore Strategico di Canale (Multiclasse):**
sddestrato solo sulle interazioni reali ($Y \neq \text{NO_ACTION}$), calcola la preferenza condizionata tra i canali attivi:

$$P(Y_{i,t} = k \mid Y_{i,t} \neq \text{NO_ACTION}, \mathbf{X}_2)$$

con $k \in \{\text{VisitF2F}, \text{SendDEM}, \text{SendRTE}, \dots\}$

Questa separazione ha aumentato sensibilmente il Recall_G sulle azioni reali, generando suggerimenti proattivi e ben distribuiti.

Dalla matrice delle variabili ($\mathbf{X}$) sono stati esclusi l'identificativo (**CONTACT_ID**), la variabile target e i KPI storici di rendimento (**clm_f2f_ratio**, **rte_click_ratio**, ecc.). Questi ultimi, oltre a ri-

schiere fenomeni di *data leakage*, presentavano troppi pochi valori ed avrebbero generato solo rumore sui dati.

3.4.3.2.1 Addestramento Modello 1: modello di saturazione (*Binary Model*)

Per bilanciare l'elevata frequenza di giorni passivi, si applica una compensazione dinamica dei pesi tramite l'iperparametro `scale_pos_weight`. L'addestramento e l'*early stopping* vengono guidati dall'area sotto la curva ROC (AUC), la quale misura la reale capacità discriminativa tra medici attivi e inattivi.

L'implementazione del modello è presentato nel Codice 4.

```
1  # Target: 0 se NO_ACTION, 1 altrimenti
2  y_binario = np.where(df_master['azione_macro'] ==
3                        'NO_ACTION', 0, 1)
4
5  # Bilanciamento dinamico dei pesi tra classi
6  peso_positivo = np.sum(y_binario == 0) /
7                  np.sum(y_binario == 1)
8
9  # Configurazione del modello con metrica AUC
10 modello_1_binario = lgb.LGBMClassifier(
11     objective='binary',
12     metric='auc',
13     scale_pos_weight=peso_positivo, # Penalizza
14     gli errori sulle azioni
15     learning_rate=0.02,
16     max_depth=7,
17     random_state=42
18 )
19
20 # Training con Early Stopping sull'AUC di
21 validazione
22 modello_1_binario.fit(
23     X_train, y_train,
24     eval_set=[(X_val, y_val)],
```

```

21     eval_metric='auc',
22     callbacks=[lgb.early_stopping(50)]
23 )

```

Codice 4: Implementazione essenziale del Modello Binario.

3.4.3.2.2 Addestramento Modello 2: selettore strategico di canale (*Multiclass Model*)

Il secondo stadio lavora solo sui dati attivi. Per evitare che i canali storicamente più frequenti (come le visite presenziali `VisitF2F`) coprano i canali digitali, si forza la ponderazione `class_weight='balanced'`, come si può vedere dal Codice 5.

```

1  # Isolamento delle sole interazioni reali
   (Esclusione NO_ACTION)
2  df_attivi = df_master[df_master['azione_macro'] !=
   'NO_ACTION']
3  X_canali = df_attivi.drop(columns=['azione_macro',
   'CONTACT_ID', ...])
4  y_canali = df_attivi['azione_macro']
5
6  # Modello Multiclasse bilanciato
7  modello_2_multiclass = lgb.LGBMClassifier(
8      objective='multiclass',
9      class_weight='balanced', # Pondera i canali
   meno frequenti
10     learning_rate=0.05,
11     random_state=42
12 )
13
14 # Training condizionato sui soli canali attivi
15 modello_2_multiclass.fit(
16     X_train_c, y_train_c,
17     eval_set=[(X_val_c, y_val_c)],
18     callbacks=[lgb.early_stopping(30)]
19 )

```

Codice 5: Implementazione essenziale del modello multiclasse.

3.4.3.3 Regole di business - Post processing

Una volta generate le probabilità grezze dai due modelli di *Machine Learning*, il sistema applica una fase di *post-processing* basata su regole di dominio aziendali (*Business Rules*). Questa fase è essenziale per raccordare i punteggi puramente statistici con gli obiettivi strategici del business, definendo l'output finale destinato ai rappresentanti farmaceutici e alla *dashboard* aziendale.

Il modello 1 restituisce la probabilità di inazione che misura il livello di saturazione o di stasi del medico. Tuttavia, affidarsi unicamente alla logica predittiva rischia di penalizzare particolari segmenti strategici, condannando a una permanente passività medici che richiederebbero invece un'azione correttiva prioritaria.

Per ovviare a questo limite, vengono applicate delle regole di override basate sul cluster di appartenenza dell'HCP:

- Cluster «Unreachable/Tech Issue»: la probabilità di inazione viene forzata artificialmente a un valore basso, attribuendo al medico una propensione all'azione.
- Cluster «Dormant»: la probabilità di inazione viene azzerata quasi del tutto per contrastare la deriva di inattività e sollecitare il riaggancio relazionale.

Parallelamente, dal modello 2 si estraggono le probabilità condizionate di preferenza per ciascun canale d'ingaggio attivo ($P(\text{VisitF2F})$, $P(\text{SendDEM})$, $P(\text{SendRTE})$, ecc.).

La raccomandazione finale (**NBA_SUGGERITA**) viene individuata applicando un operatore di massimo (argmax) sull'insieme dei canali commerciali. L'algoritmo seleziona e assegna così la strategia d'ingaggio che registra il punteggio di propensione relativa più elevato per quello specifico profilo medico.

Tutti gli output prodotti vengono consolidati in un dataset strutturato. Questo flusso viene infine persistito su una tabella aziendale in formato Delta.

3.4.3.4 Valutazione e validazione delle performance

La validazione dell'architettura gerarchica a due stadi è stata condotta analizzando separatamente l'efficacia del predittore di saturazione e la capacità discriminativa del selettore di canale.

3.4.3.4.1 Performance modello 1

Il primo stadio registra un' Accuracy globale del 61.0% Tale valore riflette il bilanciamento introdotto per evitare che il modello predica sistematicamente la classe maggioritaria di inazione, garantendo una capacità discriminativa reale tra momenti di ingaggio e fasi di riposo.

Dall'analisi della matrice di confusione (Figura 19) si osserva come il modello riesca a **intercettare correttamente il 72% delle interazioni reali (ACTION)**, assegnando al riposo solo il restante 28% dei casi. Sul fronte opposto, il 60% delle giornate prive di contatto (**NO_ACTION**) viene classificato correttamente, mentre il 40% registra una sovrastima dell'attività.




Figura 19: Matrice di confusione, modello 1.

Questa distribuzione si riflette chiaramente nell'«Indice di Saturazione» $\text{PROB_NO_ACTION} \times 100$, in Figura 20, la cui curva sulla popolazione degli HCP mostra una forma regolare con un picco principale attorno al 40%. L'impostazione della soglia di blocco operativa al 75% (caratterizzata in figura da una variazione del colore) consente di isolare nettamente la quota di medici ad alto rischio di sovraesposizione, fornendo un criterio oggettivo per sospendere temporaneamente le sollecitazioni commerciali.




Figura 20: Distribuzione indice di saturazione.

3.4.3.4.2 Performance modello 2

Isolando esclusivamente le interazioni commerciali effettive (**PhoneCall**, **RemoteCall**, **SendDEM**, **SendRTE**, **VisitF2F**), il secondo stadio dimostra una spiccata capacità di orientare la scelta strategica, raggiungendo un' Accuracy complessiva del 67.2%.

L'osservazione della matrice di confusione (Figura 21) evidenzia un'elevata precisione sulle forme di contatto dirette e digitali. Il canale **RemoteCall** si attesta come il più preciso con l' 84% di individuazioni corrette, seguito da **SendRTE** all' 81%, **PhoneCall** al 77% e **SendDEM** al 70%. Le visite in presenza (**VisitF2F**) mostrano una diagonale pari al 59%. Tale risultato è la diretta conseguenza della strategia di bilanciamento delle classi (`class_weight='balanced'`) adottata in fase di addestramento.

In assenza di tale penalizzazione, il modello tendeva a raggiungere un' *accuracy* globale ingannevolmente più elevata, ma al prezzo di una quasi totale polarizzazione su **VisitF2F**, canale nettamente maggioritario nel dataset storico. Accettando un lieve calo nell' *accuracy* di questo singolo canale, si è deliberatamente redistribuito il peso informativo favorendo la capacità discriminativa sui canali digitali e remoti, garantendo al sistema un'effettiva proattività omnicanale.




Figura 21: Matrice di confusione, modello 2.

Nello specifico della NBA Suggestita (in Figura 22), le visite presenziali (**VisitF2F**) si confermano il pilastro della relazione commerciale superando le 100.000 raccomandazioni, affiancate da un forte contributo del canale **SendDEM** con circa 70.000 suggerimenti. Le chiamate telefoniche (**PhoneCall**) e le e-mail di contenuto scientifico (**SendRTE**) coprono

rispettivamente bacini di circa 30.000 e 24.000 suggerimenti, mentre **RemoteCall** si posiziona come strumento di nicchia ad altissima precisione, consigliato per meno di 10.000 volte.




Figura 22: Distribuzione suggerimenti del modello sull'intero dataset.

3.4.3.4.3 Performance generali

L'analisi dell'output complessivo conferma che l'algoritmo non tende a schiacciarsi su un'unica tipologia di contatto, ma genera un piano d'azione multicanale articolato ed equilibrato.

Coerentemente la distribuzione mediana delle probabilità, in Figura 23, mostra la classe **NO_ACTION** con il valore mediano più alto (attorno al 0.55), agendo da naturale filtro di stasi. Tra i canali attivi spiccano **VisitF2F** con una mediana attorno al 0.34 e **SendDEM** attorno al 0.20, mentre i canali telefonici e remoti mantengono mediane più basse ma picchi molto definiti, a dimostrazione di come il modello li suggerisca in modo mirato solo in presenza di segnali d'ingaggio estremamente specifici.




Figura 23: Distribuzione mediana delle probabilità dei modelli.

3.5 Caso d'uso applicativo

A completamento del lavoro svolto, è stata preparata una *dashboard* di simulazione all'interno dell'ambiente Databricks, visibile in Figura 24. L'obiettivo della schermata non è quello di presentare uno sviluppo applicativo software finito, attività che richiederebbe un ciclo di progettazione informatica dedicato, bensì quello di mostrare concretamente i risultati del modello, abbozzando una possibile resa visiva e operativa dei dati elaborati. Le parti nel dettaglio verranno mostrate in seguito.




Figura 24: Vista generale della dashboard finale - cluster deterministico.




Figura 25: Vista generale della dashboard finale - cluster non deterministico.

L'interfaccia raccoglie in primo luogo le **generalità anagrafiche** e la specializzazione medica dell'HCP, associandole alle tassonomie strategiche definite in fase di segmentazione. Nello specifico, vengono esplicitati il cluster comportamentale, l'attitudine digitale e la posizione nell'*Adoption Ladder*.

Figura 26: Vista delle informazioni generali dell'HCP nella *dashboard*.

La sezione centrale mostra l'**Indice di Saturazione** (Figura 27) del medico, trasformato in percentuale per una lettura immediata.

L'indice viene infatti mappato dinamicamente su sei classi operative determinate da soglie aziendali ben definite:

- $\leq 10\%$: Prioritario: Ingaggio Libero (massima apertura all'ingaggio);
- $10\% - 30\%$: Ricettivo: Finestra Ideale (momento ottimale di contatto);

- 30% – 60%: Presidiato: In Target (frequenza di contatto in equilibrio);
- 60% – 80%: Quasi Saturo: Soglia Limite (evitare di non sovra-sollecitare);
- 80% – 90%: In Pausa: Raffreddamento (riduzione consigliata dell'ingaggio);
- > 90%: Saturato: Presidio Sospeso (blocco temporaneo delle comunicazioni).

Il modulo di ingaggio presenta la **graduatoria delle probabilità calcolate** (Figura 27) dal Modello 2 per i diversi canali.




Figura 27: Vista delle probabilità calcolate dai modelli.

Per rendere la raccomandazione operativa e non solo prescrittiva, il sistema applica in fase di post-processing un motore di regole tattiche basato sui tassi storici di risposta del medico.

I moduli valutano l'affinità rispetto ai link via mail (`rte_click_ratio` e `dem_click_ratio`) e l'efficacia dell'uso di materiale digitale su tablet durante le visite sul campo (`clm_f2f_ratio`). Nel caso d'uso simulato, la **sezione *Flags*** (Figura 28) genera un'indicazione specifica.

Un riquadro dedicato declina la **spiegazione qualitativa del cluster** (Figura 28), fornendo contesto sul livello di ingaggio storico per guidare l'operatore nella comprensione delle motivazioni di fondo dell'algoritmo.




Figura 28: Vista delle flags, dei cluster e del processo decisionale spiegati.

La parte inferiore della dashboard riporta la **timeline delle interazioni** (Figura 29), una matrice cronologica che traccia la sequenza temporale dei contatti passati (distinguendo tra visite sul campo, azioni web e reazioni dell'HCP come i **CLICK** registrati sulle e-mail). Questa vista completa il quadro clinico-commerciale del medico, consentendo di verificare visivamente la coerenza tra il comportamento passato e la *Next Best Action* proposta dal sistema.

Timeline Interazioni									
DATA	16/05/26	04/05/26	31/03/26	26/03/26	02/03/26	16/02/26	09/02/26	12/01/26	12/12/25
VISIT									
WEB ACTION		DEM	DEM	DEM	DEM	DEM	DEM	DEM	DEM
HCP ACTIONS	CLICK							CLICK	+

Figura 29: Vista sulla timeline all'interno della dashboard.

Capitolo 4

Conclusioni

In questo capitolo verranno trattate alcune considerazioni finali sull'attività svolta.

4.1 Consuntivo finale

Una volta terminato il progetto è stato redatto il consuntivo orario finale (in Tabella 11) che suddivide in maniera approssimata le ore dedicate alle varie fasi.

Fase	Ore
<i>Onboarding</i> del progetto.	8
Periodo di apprendimento dello stack tecnologico.	32
Studio e sperimentazione <i>Clustering</i> .	40
Produzione algoritmo di <i>Clustering</i> .	40
Studio e sperimentazioni algoritmi predittivi.	120
Produzione algoritmo predittivo.	40
Produzione documentazione e dashboard rappresentativa.	40

Fase	Ore
Totale	320

Tabella 11: Consuntivo orario finale.

4.2 Raggiungimento degli obiettivi

Al termine del progetto sono stati raggiunti la maggior parte degli obiettivi prefissati. Come su può notare in Tabella 12 in riferimento alla Sezione 2.2.1.

Codice	Descrizione	Soddisfatto
OO1	Comprensione e analisi dei dati comportamentali digitali	Sì
OO2	Sviluppo di un modello di Digital Attitude	Sì
OO3	Implementazione di modelli di classificazione e regressione	Sì
OO4	Valutazione delle performance tramite metriche statistiche.	Sì
OD1	Ottimizzazione dei modelli e miglioramento delle performance.	No
OD2	Definizione di segmentazioni utilizzabili per campagne omnicanale.	Sì

Tabella 12: Obiettivi raggiunti.

4.3 Criticità riscontrate e interventi di mitigazione

Le problematiche emerse durante lo stage e la conseguente mitigazione sono riportati in Tabella 13.

Descrizione	Mitigazione
P1 – Anomalie silenti nei dati: presenza di errori non evidenti o disallineamenti nelle tabelle di staging.	Sessioni periodiche di revisione e controllo dei dati con i referenti aziendali.
P2 – Asimmetria nelle competenze tecniche: gap iniziale di conoscenza sullo stack tecnologico aziendale.	Pianificazione di una fase di <i>onboarding</i> con l'ausilio della formazione aziendale dedicata.
P3 – Polarizzazione del modello da sbilanciamento: tendenza dell'algoritmo a predire quasi esclusivamente i canali storicamente dominanti.	Adozione della strategia di pesatura dinamica in fase di addestramento per penalizzare gli errori sui canali meno frequenti e preservare l'approccio omnicanale.
P4 – Disallineamento tra output algoritmico e logiche di ingaggio: generazione di raccomandazioni teoricamente ottimali per il modello, ma potenzialmente inefficaci o controproducenti sul piano commerciale.	Sviluppo di un motore di <i>post-processing</i> basato su regole deterministiche e soglie di business per contestualizzare e guidare le predizioni.

Tabella 13: Criticità riscontrate e interventi di mitigazione.

4.4 Valutazione personale

L'esperienza di tirocinio e lo sviluppo di questo progetto si sono rivelati altamente formativi, superando il solo valore dell'acquisizione tecnica e teorica legata agli algoritmi e alle architetture di *Machine Learning*.

Un aspetto di valore è stato l'approccio ad una metodologia di lavoro: comprendere come strutturare un progetto, definire gli step propedeutici e orientare costantemente l'analisi verso un obiettivo di business concreto. Particolarmente istruttiva è stata la gestione delle fasi di sperimentazione meno fruttuose; il riscontro di performance non ottimali in alcuni algoritmi non è stato accolto come fallimento, bensì come passaggio per affinare la comprensione del dominio di progetto e guidare le successive scelte.

Infine, il progetto ha offerto una panoramica altamente stimolante sulle reali applicazioni della *Data Science* in ambito aziendale, delineando con maggiore nitidezza i possibili sviluppi e gli sbocchi professionali futuri.

Glossario

CLM – Closed Loop Marketing: Approccio di marketing interattivo basato sulla raccolta di feedback e dati di utilizzo durante le presentazioni digitali per affinare costantemente le strategie e i contenuti. 4.

DEM – Direct-Email Marketing: Strategia di comunicazione digitale basata sull'invio di e-mail promozionali o informative mirate a un target di utenti specifico. 4.

F2F – Face to Face: Modalità di interazione diretta e di persona tra l'informatore scientifico e il professionista sanitario, in contrapposizione ai canali di contatto digitali o remoti. 4.

HCP – Healthcare Professional: Operatore sanitario qualificato a cui sono rivolte le attività di informazione scientifica e le comunicazioni di marketing farmaceutico. 3.

NBA – Next Best Action: Modello analitico guidato dai dati che suggerisce l'azione o la strategia di comunicazione più efficace da intraprendere con un cliente specifico nel momento migliore. 3.

REP – Sales Representatives: Informatore scientifico del farmaco/ agente di vendita che gestisce la relazione diretta e la comunicazione informale o commerciale con i professionisti della salute. 3.

RTE – Real-Time Engagement: Interazione in tempo reale tra operatore e utente tramite mail per offrire assistenza o informazioni immediate. 4.

Accuracy: Metrica di valutazione generale che misura la percentuale di predizioni corrette effettuate dal modello rispetto al totale delle osservazioni analizzate. Corrisponde al rapporto tra la somma di veri positivi e veri negativi e il numero totale di casi. Pur essendo immediata da interpretare, può risultare ingannevole in presenza di dataset fortemente sbilanciati, dove tende a sovrastimare le performance del modello se questo favorisce la classe maggioritaria. 47.

BA – Business Analytics: Insieme di metodologie, tecnologie statistico-matematiche e strumenti software focalizzati sull'esplorazione iterativa e sull'analisi quantitativa dei dati aziendali. Un approccio prevalentemente predittivo e prescrittivo. Attraverso l'applicazione di

modelli statistici avanzati, algoritmi di Machine Learning, data mining e tecniche di simulazione, identifica pattern nascosti, prevede trend di mercato futuri e automatizza i processi decisionali, trasformando la conoscenza estratta dai dati in un vantaggio competitivo misurabile. 1.

BI – Business Intelligence: Insieme di modelli, processi, competenze e tecnologie abilitanti volti a raccogliere, integrare, analizzare e trasformare i dati grezzi aziendali in informazioni strutturate e di valore strategico. Si focalizza primariamente sull’analisi descrittiva e diagnostica delle performance storiche e correnti dell’organizzazione. L’obiettivo fondamentale della BI è supportare i decisori aziendali (*stakeholder*) nel prendere decisioni strategiche e operative più rapide, efficaci e basate su evidenze oggettive (*data-driven*), riducendo i margini di incertezza e ottimizzando i processi di business. 1.

Clustering Gerarchico: Tecnica di clustering che raggruppa progressivamente gli elementi in base alla loro similarità, creando una struttura gerarchica di gruppi (*cluster*). Il processo può partire da singoli elementi, che vengono via via uniti nei gruppi più simili, oppure da un unico gruppo che viene progressivamente suddiviso. 29.

Clustering: Tecnica di apprendimento non supervisionato (*Unsupervised Learning*) finalizzata al raggruppamento di un insieme di oggetti o record di un dataset in classi (dette cluster) omogenee. 5.

dashboard: Interfaccia grafica centralizzata che organizza, visualizza e presenta in modo sintetico e intuitivo le metriche chiave e le informazioni aziendali fondamentali per il monitoraggio di un determinato processo o business. 2.

Data-Science: Disciplina interdisciplinare che combina metodi scientifici, processi statistico-matematici, algoritmi di Machine Learning e sistemi informatici al fine di estrarre conoscenza, pattern complessi e insight di valore da grandi volumi di dati strutturati e non strutturati. 5.

Data Visualization: Insieme di tecniche, metodologie e strumenti grafici volti a rappresentare visivamente dati e informazioni complesse. Attraverso l’uso di elementi visivi come grafici, mappe, diagrammi e dashboard interattive, la Trasforma dati grezzi o output di modelli analitici in formati intuitivi e di immediata comprensione. 7.

DBSCAN: Algoritmo di clustering basato sulla densità che raggruppa gli elementi che si trovano in aree ad alta concentrazione e identifica come “rumore” o outlier gli elementi isolati. A differenza di altri metodi di clustering, non richiede di stabilire in anticipo il numero

di cluster. È particolarmente utile per individuare gruppi di forma irregolare e dati anomali. 29.

Forecasting – Analisi predittiva temporale: Processo di stima e previsione dell'evoluzione futura di una specifica variabile quantitativa, basato sull'analisi storica di serie temporali e trend passati. 6.

Gradient Boosting: Tecnica di machine learning che combina in modo sequenziale più modelli semplici, generalmente alberi decisionali, per costruire un modello predittivo più accurato. Ogni nuovo modello viene addestrato per correggere gli errori commessi dai modelli precedenti. Il risultato finale è quindi l'insieme dei contributi di tutti i modelli costruiti progressivamente. 39.

inerzia: Misura della dispersione dei punti all'interno dei cluster rispetto al centroide del proprio cluster. Indica quanto gli elementi di ciascun gruppo sono vicini o lontani dal proprio centro. Un valore di WCSS più basso indica cluster più compatti e quindi, generalmente, una maggiore coesione interna. 29.

insight – Data insight: Comprensione profonda, chiara e precedentemente non evidente di uno specifico fenomeno o comportamento, ottenuta attraverso l'elaborazione, l'analisi e l'interpretazione di grandi volumi di dati. Nel contesto degli Advanced Analytics e del Machine Learning, la generazione di insight di valore è l'obiettivo fondamentale che permette di guidare le strategie prescrittive, come l'individuazione della Next Best Action ottimale. 2.

Label Encoding: Tecnica di pre-elaborazione dei dati che converte ciascuna categoria unica di una variabile categoriale in un valore numerico intero (es. da 0 a $N - 1$). A differenza del One-Hot Encoding, non crea nuove colonne, ma sostituisce direttamente le stringhe con numeri. 42.

Delta Lake: Formato di archiviazione open-source basato su file Parquet che aggiunge un livello di affidabilità, governance e prestazioni ai Data Lake. Sviluppato da Databricks, abilita l'architettura Data Lakehouse introducendo il supporto alle transazioni ACID, l'applicazione rigida dello schema (schema enforcement), l'indicizzazione avanzata e il versionamento dei dati (time travel), consentendo di interrogare e ripristinare lo stato storico delle tabelle. 15.

Data Lakehouse: Architettura di gestione dati che combina gli elementi chiave dei Data Lake (scalabilità, flessibilità e costi contenuti nel salvataggio di dati strutturati e non) con le funzionalità tipiche dei Data Warehouse (prestazioni elevate, consistenza delle transazioni ACID, supporto a query SQL e governance del dato). Consente di

eseguire sia analisi di Business Intelligence sia flussi di Data Science e Machine Learning su un'unica piattaforma integrata. 15.

MLFlow: Piattaforma open-source per la gestione end-to-end del ciclo di vita dei modelli di Machine Learning. Sviluppata da Databricks, offre strumenti integrati per il tracciamento degli esperimenti e dei parametri (MLflow Tracking), la riproducibilità del codice (MLflow Projects), il salvataggio e la gestione dei formati di modello (MLflow Models) e un registro centralizzato per il versionamento e il deployment (MLflow Model Registry). 15.

One-Hot Encoding: Tecnica di pre-elaborazione dei dati usata nel Machine Learning per convertire variabili categoriali in un formato numerico binario. Per ciascuna categoria unica della variabile viene creata una nuova colonna (chiamata *dummy variable*): la colonna assume valore 1 in corrispondenza della classe appartenente e 0 per tutte le altre, evitando di introdurre relazioni d'ordine artificiali tra le categorie. 42.

PoC – Proof of Concept: Realizzazione preliminare, incompleta o in scala ridotta di un progetto software, di un algoritmo o di un'architettura tecnologica, sviluppata al fine di dimostrarne la fattibilità tecnica e la validità concettuale prima di procedere con l'effettiva implementazione su larga scala. 2.

Recall: Metrica di valutazione delle performance di un modello di classificazione che misura la capacità dell'algoritmo di individuare tutti i casi reali appartenenti a una determinata classe. Corrisponde alla percentuale di veri positivi identificati rispetto al totale dei casi reali positivi ($\frac{\text{Veri Positivi}}{\text{Veri Positivi} + \text{Falsi Negativi}}$). Risulta particolarmente critica in scenari in cui mancare un evento positivo comporta un costo elevato. 47.

stocastico: Si dice di un processo, fenomeno o sistema il cui comportamento è governato da leggi probabilistiche e dal caso, invece che da regole deterministiche. In un processo stocastico, dato un determinato stato iniziale, non è possibile predire con certezza l'esito futuro, ma solo la probabilità con cui i diversi risultati si possono verificare. 39.

varianza: Misura statistica della dispersione dei dati rispetto alla loro media. Indica quanto, mediamente, i valori di un insieme di dati si discostano dalla media, considerando il quadrato degli scostamenti. 25.

Sitografia

- Abhay Singh. (2024, marzo 3). *LightGBM Explained: Faster and Smarter Gradient Boosting*. Medium. <https://medium.com/@abhaysingh71711/lightgbm-explained-faster-and-smarter-gradient-boosting-4ab549629925>
- Adesuwa Okosun. (2024,). *Machine Learning 101*. Medium. <https://medium.com/@adesuwaokosun/machine-learning-101-4c3309a0af09>
- Apache Software Foundation. (s.d.). *PySpark Documentation*. Apache Spark. Recuperato <https://spark.apache.org/docs/latest/>
- Brian Clark, & Fangfang Lee. (2026,). *What is Gradient Boosting?*. IBM Think. <https://www.ibm.com/think/topics/gradient-boosting>
- CatBoost Development Team. (s.d.). *CatBoost Documentation*. CatBoost. Recuperato <https://catboost.ai/docs/>
- Data Science Collective. (s.d.). *Markov Chains for Humans: The Simplest Way to Predict What's Next*. Medium. Recuperato <https://medium.com/data-science-collective/markov-chains-for-humans-the-simplest-way-to-predict-whats-next-e9939d63d4c0>
- Databricks Inc. (s.d.-b). *Dashboards in Databricks*. Databricks Documentation. Recuperato <https://docs.databricks.com/aws/en/dashboards/>
- Databricks Inc. (s.d.-a). *Databricks Documentation*. Databricks. Recuperato <https://docs.databricks.com/aws/en/>
- Google. (2026,). *Gemini*. Large Language Model. <https://gemini.google.com/>
- IBM. (s.d.-b). *Che cos'è il clustering k-means?*. IBM Think. Recuperato <https://www.ibm.com/it-it/think/topics/k-means-clustering>
- IBM. (s.d.-a). *Che cos'è il clustering?*. IBM Think. Recuperato <https://www.ibm.com/it-it/think/topics/clustering>
- LightGBM Contributors. (s.d.). *LightGBM Documentation*. Read the Docs. Recuperato <https://lightgbm.readthedocs.io/en/stable/>

Python Software Foundation. (s.d.). *Python Documentation*. Python Software Foundation. Recuperato <https://docs.python.org/3/>

Redazione AI4Business. (s.d.). *La Catena di Markov: cos'è e come si colloca nella Data Science*. AI4Business. Recuperato <https://www.ai4business.it/intelligenza-artificiale/la-catena-di-markov-cose-come-si-colloca-nella-data-science/>

Scikit-learn Developers. (s.d.). *sklearn.cluster.KMeans*. scikit-learn documentation. Recuperato <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>

Wikipedia Contributors. (s.d.). *Markov chain*. Wikipedia, The Free Encyclopedia. Recuperato https://en.wikipedia.org/wiki/Markov_chain